

Análise de Tendências de Mercado por Redes Neurais Artificiais

Carlos E. Thomaz¹ e Marley M.B.R. Vellasco²

¹*Departamento de Engenharia Elétrica (IAAA), FEI, São Paulo, Brasil*

²*Departamento de Engenharia Elétrica (ICA), PUC-RJ, Rio de Janeiro, Brasil*

cet@fei.edu.br, marley@ele.puc-rio.br

Abstract

Este trabalho tem por objetivo avaliar, através de um modelo numérico estrutural simplificado, uma metodologia de análise de tendências de curto prazo para série de preços de ativos financeiros. Um ativo financeiro pode apresentar, basicamente, três tipos de tendência : alta, baixa e sem tendência. Desta forma, o modelo em questão deve determinar as tendências de curto prazo das ações de TELEBRAS PN e, ainda mais importante, as suas mudanças. A rede utiliza como dados de entrada as variações percentuais diárias das cotações médias de TELEBRAS PN, obtidas através de um banco de dados histórico. O algoritmo neural implementado para esta aplicação é o Self-Organizing Network (Competitive Learning), cujo mapeamento classifica os vetores de entrada nas três possíveis tendências já descritas. Para executar esta Rede Neural, o usuário deve dispor do software MatLab (versão 4.2 ou superior) com a caixa de ferramentas de redes neurais (Neural Network Toolbox) instalada.

1. Introdução

Preços de ações negociadas em mercado apresentam um padrão oscilatório de alternância de movimentos de alta e de baixa no decorrer do tempo, em consonância com o processo de realinhamento dos valores relativos na economia. Esta alternância pode ser derivada do processo de ajustamento dos preços ao conteúdo de informações difundidas relacionadas às empresas emissoras desses títulos e às contínuas modificações na condução da política e da economia nacionais e internacionais [2].

Com isto, para obter ganhos no mercado financeiro, muitos operadores ("traders") procuram prever esses movimentos de alta ou de baixa, obtendo indicações antecipadas de quando comprar ou vender determinada ação. Nesses casos, esses operadores não estão muito preocupados com a direção do mercado em si, mas sim com a possibilidade do mesmo em se mover por

significante espaço de tempo num determinado sentido ("the trend is your friend").

Uma variedade de métodos tem sido utilizada para tentar estimar o comportamento de séries de dados financeiros, tais como: médias móveis e linhas de tendência [1]. De forma sucinta, média móvel é um procedimento matemático para suavizar ou eliminar flutuações nos dados de série temporais e linha de tendência é uma linha reta desenhada em um gráfico de preços que conecta uma série de picos ou de vales deste gráfico. No entanto, pesquisas indicam que análises de séries temporais baseadas em Redes Neurais têm apresentado resultados superiores [1, 4].

Este trabalho tem por objetivo fazer com que a rede neural detecte o movimento de curto prazo do ativo financeiro Telebras PN, apresentando uma solução alternativa para análise de tendências de mercado. As ações de Telebras PN foram escolhidas para esse estudo pois apresentavam o maior volume de negócios entre todas as empresas brasileiras existentes na Bolsa de Valores de São Paulo (Brasil) na década de 90.

2. Descrição do Problema

Embora pareça relativamente simples identificar se um mercado está se movendo em tendência ou não, para o olho humano isto pode ser difícil de perceber. Na figura 1, são apresentadas duas séries de dados que exemplificam esse fato. Uma série foi gerada de forma aleatória, ou seja, os valores consecutivos não estão correlacionados [1]. A outra é uma série de tendências onde os dados possuem uma correlação entre si e, assim, quando o valor mais recente sobe (desce), a probabilidade de a série subir no dia seguinte (descer) é maior, de 60%. Observando apenas estes dois gráficos, fica difícil afirmar qual série é aleatória e qual é de tendência. Ambas parecem ser correlacionadas, mas somente a série B é uma série de preços de tendência.

Desta forma, como as Redes Neurais são dispositivos não-lineares que extraem as propriedades estatísticas de um grupo de dados de entrada, as




Figura 1. Série A versus série B.

mesmas são vistas como uma solução promissora para o problema em questão. Através de um processo de treinamento, os modelos neurais são capazes de reconhecer padrões, agrupando entradas similares (movimentos parecidos do ativo financeiro) em tipos de classes [3, 4].

Neste trabalho, a série analisada é composta pelos preços diários das cotações médias de fechamento das ações de Telebras PN, desde Janeiro de 1995 até Maio de 1997 (figura 2). Pela figura 2, pode-se notar que desde final de Fevereiro de 1995 as ações de Telebras PN descrevem um movimento de alta. No período compreendido entre início de Julho e final de Dezembro de 1996 (região destacada no gráfico), o ativo apresentou uma atenuação prolongada deste movimento, "andando de lado" nestes meses (mercado sem tendência). Estes movimentos que perduram por meses e por anos são conhecidos como tendências de médio e longo prazo, respectivamente. Tendências de curto prazo são aquelas compreendidas entre duas ou três semanas, e estes são exatamente os movimentos a serem analisados pelo modelo em questão.

Figura 2. Gráfico de preços das ações Telebras PN.

3. Descrição da Solução

Os modelos neurais chamados de "Self-Organizing Networks" são redes de uma camada capazes de aprender a detectar regularidades (correlações) entre

suas entradas, adaptando as respostas futuras de acordo com o conhecimento armazenado. O mapeamento das redes "Self-Organizing" aprende a reconhecer grupos de vetores de entrada de tal forma que vetores similares ativem o mesmo neurônio. Estes modelos possuem algoritmos de treinamento não supervisionado e geralmente são baseados em um método de competição entre os neurônios [3, 4].

O método de competição utilizado neste projeto foi aquele conhecido como "Competitive Learning" [3, 4], que ajusta somente o peso do neurônio vencedor (neurônio mais próximo do vetor de entrada - "winner takes all"). Como o objetivo é analisar tendências de curto prazo, que compreendem oscilações com duração de dez (10) dias úteis aproximadamente, a rede neural foi implementada com dez (10) entradas. Estas entradas correspondem às variações percentuais diárias (normalizadas) das cotações médias das ações de Telebras PN, pois deseja-se identificar apenas se o preço da ação subiu ou caiu com relação ao dia anterior, não importando seu valor absoluto (transparente). Além disto, o vetor de saída foi implementado com três dimensões, permitindo a classificação dos vetores de entrada nos três tipos de padrão: tendência de alta, tendência de baixa e sem tendência.

Os dados diários históricos de 1995 e 1996 foram utilizados para treinamento da rede, restando os dados de 1997 para teste. Os vetores de treinamento foram arrumados em janelas com passo de deslocamento igual a dez (10) variações diárias, conforme os retângulos verticais desenhados na figura 3. Esta segmentação transformou os dados de treinamento em cinquenta (50) vetores de entrada com nenhuma ou pouca similaridade entre si, compostos em grande maioria por movimentos típicos de alta e de sem tendência. Para equilibrar estas estatísticas, os vetores pertencentes a região de baixa destacada na figura 3 (região esférica) foram repetidos, aumentando o conjunto de treinamento para sessenta (60) vetores de entrada.




Figura 3. Composição da matriz de treinamento. Os vetores são as variações diárias das cotações contidas nas janelas.

O treinamento da rede foi feito através de uma rotina desenvolvida no software MatLab. Esta rotina recebe três parâmetros: matriz de dados, número de classes e número de ciclos de treinamento. A matriz de dados é a matriz de treinamento formada pelas variações percentuais diárias normalizadas (figura 3). O número de classes é igual a 3 (três), pois pretende-se classificar a série de preços em três movimentos (padrões). E, por fim, o número de ciclos de treinamento é posto igual a 500 (quinhentos), já que os vetores de treinamento devem ser apresentados à rede de forma aleatória e repetitiva.

Para a recuperação da informação pela rede, implementou-se uma outra rotina em Matlab. Esta rotina recebe como parâmetros o vetor de entrada a ser classificado e a matriz de pesos da rede treinada. Antes de se aplicar os dados de teste na rede, teve-se que identificar se os três neurônios eram ativos e qual deles respondia por cada classe. Esta identificação foi feita aplicando-se na entrada vetores com tendência bem definida (somente variações positivas, somente variações negativas, e variações positivas e negativas), permitindo descobrir a relação neurônio/tendência da Rede Neural (figura 4).

```
[+1;+1;...;+1] → Neurônio 3 (tendência de alta)
[-1;-1;...;-1] → Neurônio 2 (tendência de baixa)
[+1;-1;...;-1] → Neurônio 1 (sem tendência)
```

Figura 4. Determinação da relação neurônio/tendência.

Uma vez identificado quais neurônios respondiam por que classes, os dados de 1997 foram apresentados à rede. Estes dados foram arrumados de duas formas, como mostra a figura 5 seguinte. Pode-se notar (figura 5 - gráfico inferior) que a matriz 2 de teste é formada

por vetores com janelas de passo de deslocamento igual a 1 (uma) variação, diferente do passo atribuído aos vetores de treinamento (figura 3). A idéia de testar a rede com estes dados é verificar a capacidade da mesma em detectar mudanças de tendência, uma vez que esta tenha aprendido a reconhecer os três tipos de padrões já citados.




Figura 5. Formação das duas matrizes de teste.

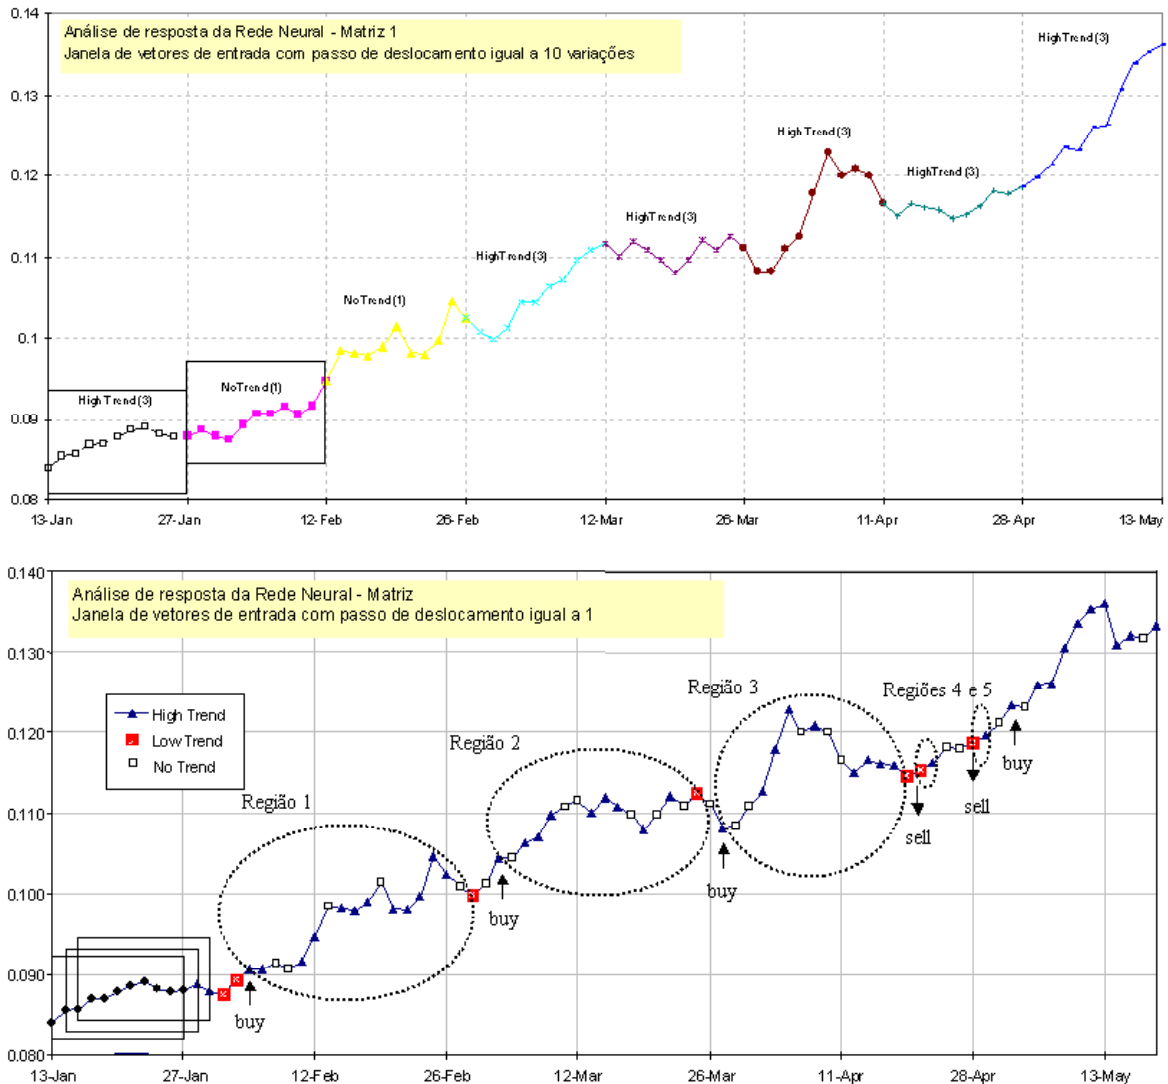


Figura 6. Análise das respostas da Rede Neural sobre o gráfico das cotações médias de Telebras PN.

4. Resultados

A rede neural classificou as duas matrizes de teste de acordo com os gráficos apresentados na figura 6.

O primeiro gráfico da figura 6 se refere às respostas da rede para a matriz 1 de teste. Pode-se verificar que para todos os oito segmentos (janelas) apresentados como vetores de entrada, a rede ativou 6 (seis) vezes o neurônio 3 relativo a tendência de alta e 2 (duas) vezes o neurônio 1 correspondente a mercado sem tendência. Estes resultados, embora não tenham nenhum sentido prático para o investidor de ações, servem para validar o reconhecimento de padrões aprendido pela rede. Apesar de algumas sinalizações incorretas, devido ao

número limitado de exemplos para os movimentos de tendência de baixa e sem tendência, acreditamos que o aprendizado fora suficientemente satisfatório.

O segundo gráfico representa a resposta da rede para a matriz 2 de teste. Neste caso, os vetores de entrada foram formados deslocando-se a janela de dados uma cotação para direita (retângulos maiores desenhados), de forma a manter seu tamanho constante (10 variações percentuais diárias). Com isto, a rede neural varreu sequencialmente todas as cotações de Telebras PN compreendidas no período de 13 de Janeiro até 16 de Maio de 1997, respondendo dia após dia em qual tendência o ativo financeiro se encontrava - tendência de alta ("high trend"), tendência de baixa

Tabela 1. Indicações de compra e venda sinalizadas pelo modelo neural.

Região	Sinal Rede Neural	Entrada da Posição		Saída da Posição		Resultado ((PS-PE)/PE) * 100
		Data	Preço (PE)	Data	Preço (PS)	
1	Compra	03-Feb	0.0906	28-Feb	0.0998	10.15%
2	Compra	04-Mar	0.1044	25-Mar	0.1125	7.76%
3	Compra	31-Mar	0.1082	18-Apr	0.1148	6.10%
4	Venda	22-Apr	0.1152	23-Apr	0.1162	-0.87%
5	Venda	28-Apr	0.1186	29-Apr	0.1196	-0.84%

("low trend") ou sem tendência ("no trend"), conforme legenda do gráfico (figura 6). Pode-se destacar, então, cinco regiões (círculos pontilhados) correspondentes às reversões de movimento sinalizadas pela rede. Estas reversões podem ser interpretadas como pontos de compra ("buy") e de venda ("sell") das ações em questão. A tabela 1 acima apresenta os possíveis resultados obtidos pelo investidor caso o mesmo tivesse se posicionado segundo as indicações dadas pelo modelo neural.

5. Conclusão

Os resultados confirmam a potencialidade das Redes Neurais na estimação do comportamento de séries de dados financeiros.

O modelo neural desenvolvido reconheceu de forma coerente as oscilações dos movimentos de alta e de baixa das ações de Telebras PN, demonstrando-se uma ferramenta bastante útil na análise de tendências de curto prazo. Pode-se destacar duas características importantes deste modelo. A primeira se refere à classificação correta pela rede das principais tendências de alta das ações de Telebras PN, apresentando lucrativas sinalizações de início e de término de posições de compra. A segunda característica se baseia nos falsos pontos de venda indicados pela rede que foram corrigidos rapidamente (1 dia), não resultando em prejuízos expressivos. Além disto, é válido ressaltar que este classificador pode ser aplicado a qualquer ativo financeiro, podendo realizar, também, análises em tempo real (variações "on-line").

Observou-se, no entanto, que o desempenho da rede pode ser melhorado se o número de padrões apresentado à mesma for aumentado. Isto permitirá uma maior diversidade nas amostras de movimentos de baixa e sem tendência das ações de Telebras PN, pouco caracterizadas nos anos de 1995, 1996 e 1997. Como análise futura, pode-se fazer o treinamento desta mesma rede com uma massa de dados maior (desde 1993) que englobe as quedas de preço desse ativo financeiro e garanta resultados mais robustos.

No contexto, uma extensão interessante para este trabalho seria a implementação de redes neurais para a análise de tendências de média e longo prazo - com duração de meses e anos, respectivamente - também muito importantes para o mercado financeiro. Além disso, um estudo comparativo com outras técnicas tradicionais de Redes Neurais, tal como o algoritmo de aprendizado "backpropagation", seria de extrema relevância para avaliar melhor o método proposto.

Referências

- [1] J. K. Hutson, *Technical Analysis of Stock and Commodities*, vol. 13, 1995.
- [2] M. D. F. Tavares, *Análise Técnica: Gráfico de Barras*, IBMEC – Rio de Janeiro, pp. 5-14, 1987.
- [3] P. D. Wasserman, *Neural Computing – Theory and Practice*, Van Nostrand Reinhold, 1989.
- [4] J. M. Zurada, *Introduction to Artificial Neural Networks*, West Publishing Company, 1992.