



**Business Intelligence**

**PUC**  
RIO

*Daniel Medeiros*

*Redes Neurais para previsão de valor futuro  
dos preços de ações.*

*Monografia de Final de Curso*

~~31/08/2015~~18/05/2011

***Monografia apresentada ao Departamento de Engenharia Elétrica da  
PUC/Rio como parte dos requisitos para a obtenção do título de  
Especialização em Business Intelligence.***

***Orientadores:***

Juan Guillermo Lazo Lazo

---



## **Dedicatória**

Este trabalho é dedicado à memória de minha irmã Rachel que infelizmente veio a nos deixar durante sua realização, aos meus pais, Angela e Ruy e minha querida namorada Ana Carolina.

## Resumo

Devido aos bons resultados obtidos pelo uso de redes neurais em aplicações voltadas ao mercado financeiro, seu uso tem crescido bastante nos últimos anos. As redes neurais ajudam na análise de diversos indicadores visando à previsão do valor futuro de uma determinada ação. A dificuldade encontrada é que não existe um único indicador que nos dê essa resposta e sim um conjunto de indicadores onde cada um trás uma informação diferente. Analisando todas essas informações é possível estimar a tendência do preço futuro. Porém, devido ao grande número de indicadores, o ser humano tem muita dificuldade em analisar essas informações fornecidas pelos indicadores para determinar a tendência de uma ação.

Este trabalho propõe o uso de uma rede neural feedforward, multicamada com aprendizado backpropagation para analisar todos os indicadores e fornecer para o usuário informações se o preço de uma determinada ação irá subir quatro por cento num horizonte de quatro dias, sugerindo assim a compra desse ativo. Com esse resultado, o investidor terá menor risco na hora de escolher em qual ação investir, além de ter um prévio conhecimento do comportamento do ativo escolhido.

## **Abstract**

Due to the good results obtained by using neural networks in applications related to financial markets, its use has grown considerably in recent years. Neural networks help in the analysis of several indicators, aiming to predict the future value of a particular action. The difficulty and that there is not one indicator that gives us that answer, but a set of indicators where each bring different information. Analyzing all this information is possible to estimate the future price trend. However, due to the large number of indicators, humans have great difficulty in analyzing information provided by these indicators to determine the trend of a stock.

This paper proposes the use of a multilayer feedforward neural network, with backpropagation learning to analyze all the indicators and provide information to the user if the price of a particular stock will rise four percent in a horizon of four days, suggesting the purchase of assets. With this result, the investor will have less risk in choosing what stock to invest, besides having a prior knowledge of behavior of the asset selected.

## Sumário

1-Introdução.....	1
1.1 Motivação.....	1
1.2 Objetivos.....	2
1.3 Justificativa.....	2
1.4 Estrutura do trabalho.....	3
2-Indicadores.....	4
2.1 Índice de Força Relativa (IFR).....	4
2.2 Banda de Bollinger.....	5
2.3 Média Móvel.....	6
2.3.1 Média Móvel Aritmética.....	6
2.3.1 Média Móvel Exponencial.....	7
2.4 MACD.....	8
2.5 DIDI Index.....	10
3-Redes Neurais.....	11
3.1 Introdução.....	11
3.2 Conceitos Básicos.....	11
3.3 Processos de Aprendizagem.....	14
3.4 Rede Neural Backpropagation.....	16
3.5 Projetos de Redes Neurais e suas vantagens.....	17
4-Aplicações e Resultados Obtidos.....	19
4.1 Tratamento dos dados.....	19
4.2 Seleção das Variáveis.....	19
4.3 Arquitetura Proposta.....	20
5-Resultados Obtidos.....	22
6-Conclusões.....	25

# 1-Introdução

## 1.1 Motivação

Como o mercado de ações além de ser um importante meio de financiamento empresarial, assim como de captação de finanças individuais, vem adquirindo cada vez mais importância no cenário internacional.

Devido a todo esse crescimento pelo interesse no mercado de ações, a concorrência entre os bancos de investimentos e acionistas individuais aumentou significativamente, levando a todos a tentar prever da maneira mais eficiente e próxima da realidade, o comportamento de tais ações. Para essas previsões tem-se usado, com frequência, técnicas computacionais, matemáticas e estatísticas para tentar modelar o movimento futuro do mercado financeiro a partir de uma base de dados do passado.

As Redes Neurais, uma técnica computacional de grande importância para essas previsões, é bastante indicada para esse tipo de problema graças a sua forma não-linear de analisar dados, diferente das outras técnicas computacionais.

Em um sistema computacional comum, o usuário deve prever, ou pelo menos tentar prever todas as situações que possam vir a acontecer para que o programa gere uma resposta ao problema. Como nós sabemos, no mercado financeiro, não é possível antecipar todas essas situações, visto que sofrem influências políticas, econômicas, causas naturais entre outras.

Como as Redes Neurais tentam funcionar como o cérebro humano, adquirindo o conhecimento através de um processo de treinamento de tentativa e erro, isso lhe dá possibilidades de obter melhores resultados ao tratar de problemas não-lineares como são os do mercado financeiro.

Trabalhos anteriores nos mostram a superioridade das Redes Neurais em relação aos outros métodos citados acima para se tratar desse problema de previsão do comportamento de ativos financeiros. Devido aos excelentes resultados obtidos, e demonstrado nesses trabalhos, as Redes Neurais tem ganhado força como ferramenta de previsão e se difundindo bastante entre os analistas técnicos de mercado.

Devido aos grandes riscos enfrentados no mercado financeiro, os investidores esperam obter um retorno alto suficiente se opor ao risco que está enfrentando. As Redes Neurais, como demonstrado nesses trabalhos citados, ajudam os investidores a fazer uma previsão futura dos preços das ações negociadas na bolsa, para que possam montar sua carteira da forma mais eficiente possível, ou seja, que de o maior retorno oferecendo o menor risco.

Como as Redes Neurais conseguem lidar de uma maneira simples com informações que possuem um grau de incerteza, variabilidade e não-linearidade elevados, são muito indicadas para problemas financeiros de previsão futura. Por esses motivos elas são mais eficientes para esse tipo de problema que os métodos estatísticos e matemáticos, tornando a tomada de decisão mais segura e rápida possível.

## **1.2 Objetivos**

Desenvolver e implementar uma rede neural capaz de realizar uma estratégia de compra de um determinado ativo financeiro, de modo que garanta um lucro igual ou superior a 4% nos próximos quatro dias, tomando como entrada seus valores de abertura, máximo, mínimo e fechamento passados e também diversos indicadores de análise técnica desenvolvidos ao longo dos anos que ajudam aos investidores identificar padrões de reversão e tomar a decisão de quando entrar ou sair do mercado.

Com base nessas previsões o investidor pode montar uma carteira que lhe ofereça o maior retorno com o menor risco possível.

Esse trabalho também tem como objetivo analisar a aplicabilidade das redes neurais e modelar da forma mais eficiente os dados de entradas para que os resultados da rede sejam considerados satisfatórios.

## **1.3 Justificativa**

Há muito tempo tenta-se realizar a previsão, por diversos métodos diferentes, a previsão dos valores futuros dos ativos negociados na bolsa de valores. A fim de auxiliar e tornar a decisão do investidor mais fácil, as redes neurais vem ganhando bastante força.

Esse processo de análise de todos os indicadores usados na tentativa de prever os valores futuros envolve um espaço de busca muito amplo e não-linear, tornando-o impossível de avaliar todas as possíveis combinações.

Antigamente, antes do avanço dos computadores até chegarem ao que são hoje em dia, as operações eram baseadas no pressentimento dos investidores. À medida que os computadores se desenvolveram e o valor negociado no mercado de ações aumentava houve uma grande procura por ferramentas computacionais que auxiliasse na tomada de decisão e diminuísse seu risco.



Com o avanço dos computadores, um novo método pode ser desenvolvido para superar os problemas encontrados por todos os outros métodos já existentes de previsão de valores futuros de ações. Esse método, conhecido como Rede Neural artificial procura modelar a forma de processamento de informação usado pelo cérebro humano no computador, tornando-o então capaz de realizar funções como aprendizado. Desta forma as redes neurais artificiais conseguem identificar padrões não-lineares nos dados de entrada e extrair regras sem que sejam formalizadas explicitamente.

Devido a essas propriedades presentes nas Redes Neurais artificiais, muitos pesquisadores acreditam que este seja o melhor método de se modelar sistemas não-lineares como os de previsão de valor futuro de um ativo negociado no mercado de ações.

## **1.4 Estrutura do Trabalho**

Este trabalho está estruturado em seis capítulos.

O segundo capítulo faz uma breve descrição dos diversos indicadores de análise técnica que serão utilizados como dados de entradas para as Redes Neurais.

O terceiro capítulo descreve o que são e como funcionam as Redes Neurais Artificiais, passando pelos principais tipos, como se dá o seu aprendizado e suas principais aplicações.

No quarto capítulo encontra-se a arquitetura proposta para resolver o problema de previsão de preços dos ativos negociados no mercado de ações.

No quinto capítulo serão apresentados os resultados obtidos pela Rede Neural Artificial proposta pelo trabalho.

E no sexto capítulo serão apresentadas as conclusões sobre o uso de redes neurais para prever o valor futuro dos ativos negociado na bolsa e também serão apresentadas sugestões para trabalho e pesquisas futuras.

## 2-Indicadores

### 2.1 Índice de Força Relativa (IFR)

Oscilador desenvolvido por Welles Wilder em meados de 1978 e detalhado em seu livro “New Concepts in Technical Trading Systems” que se tornou muito popular entre os analistas técnicos devido aos seus bons resultados. Apesar de ser muito simples de ser calculado seu uso pode ser um pouco mais complicado.

O nome mais apropriado para ele seria Índice de Força Interna, pois o IFR na verdade compara a força interna entre dois momentos de um único ativo e não a força entre dois ativos diferente como seu nome pode induzir.

Para calcularmos o IFR usamos a fórmula  $100 - 100/(1+U/D)$ , onde U é a média das cotações dos últimos N dias onde a cotação subiu e D é a média das cotações dos últimos N dias onde a cotação desceu.

Wilder recomendou um cálculo do indicador para 14 dias, mas existem analistas que usam o IFR de nove ou 25 dias.

Para calcularmos o IFR de catorze dias, por exemplo, basta somarmos todas as cotações dos últimos catorze dias em que houve alta do valor do ativo e dividir por catorze para obter U. De modo análogo somamos todas as cotações dos últimos catorze dias em que houve baixa do ativo e dividimos também por catorze para obtermos D. Agora basta aplicar a fórmula e repetir esse procedimento para um número suficiente de datas até que se possa traçar um gráfico para ser analisado.

O IFR varia entre zero e cem. Quando o valor estiver acima de 70 dizemos que o IFR entrou na região de sobrecomprado e quando cai abaixo de 30 dizemos que está na região de sobrevendido. Alguns traders preferem definir as regiões de sobrecomprado e sobrevendido como acima de 80 e abaixo de 20 respectivamente, cabendo a cada analista definir esses pontos em função dos resultados obtidos.

Há basicamente três análises gráficas que se pode retirar de um gráfico de IFR:

- A interpretação mais simplista que pode ser feita é em relação às saídas das regiões de sobrecomprado/sobrevendido. Sempre que o IFR caia abaixo dos 70/80 pontos depois de ter estado numa região de sobrecomprado é gerado um sinal de venda do título. Analogamente quando o IFR sai de uma região de sobrevendido e passa dos 30/20 pontos é gerado um sinal de compra do título.
- Outra interpretação que pode ser feita do gráfico de IFR são as divergências que talvez seja a maior virtude deste indicador. Sempre que a cotação atingir novos máximos e o gráfico do IFR não acompanhar (indicador falha a fazer um topo mais

alto) é provável que a cotação do título corrija através de queda. Do mesmo modo que se a cotação do título teste novos mínimo e o IFR não acompanhar (indicador falha a fazer um fundo mais baixo que o anterior) é provável que a cotação do título suba.

- O gráfico de IFR também serve para traçar linhas de resistência/suporte/tendência da mesma forma que são traçadas no gráfico de cotações.

## 2.2 Bandas de Bollinger

Essa ferramenta de análise técnica foi criada por John Bollinger no início dos anos 80 e é descrito em seu livro “Bollinger on Bollinger Bands”. Esse indicador possui uma forte relação com a volatilidade, ajudando na antecipação de fortes movimentos e na identificação de pontos de compra e venda.

As bandas de Bollinger são formadas por um conjunto de três curvas desenhadas em relação aos preços do ativo.

A banda intermediária, geralmente obtida com uma média móvel simples de 20 dias, serve como base para as bandas superiores e inferiores. O intervalo entre as bandas intermediárias, superiores e inferiores é determinado pela volatilidade, geralmente o desvio padrão das mesmas datas que foram utilizadas pela média móvel. Assim quanto maior a volatilidade de um ativo, maior seu desvio padrão.

Como a média móvel amortece muito o valor da cotação, alguns traders preferem usar o desvio padrão do fechamento do ativo, já que a variação é maior, ao invés do desvio padrão da média móvel usada para calcular a banda intermediária. Em termos de cálculos tem-se;

Banda Superior = banda intermediária + 2\*desvio padrão

Banda Inferior = banda intermediária - 2\*desvio padrão

Podemos interpretar as bandas de Bollinger de algumas maneiras diferentes:

- Estreitamento das bandas: ocorre quando acontece uma diminuição da volatilidade de um ativo, aproximando as bandas e formando um canal muito estreito. Podemos comparar esse momento com a calma que antecede a tempestade. Nesse momento as bandas estão sinalizando uma oportunidade de forte movimento. Porém devemos tomar cuidado e utilizar as bandas em conjunto com outros indicadores, pois não sabemos se o movimento vai ser alto ou de baixa.

- Alcançando as bandas: quando a cotação alcança uma das bandas, consideramos o mercado comprado ou vendido. Esse momento é considerado favorável para entrar no mercado se estiver vendido, ou sair dele se estiver comprado. O gráfico ao tocar ou cruzar a banda superior pode ser considerado comprado e de maneira oposta pode ser considerado vendido ao tocar ou cruzar a linha inferior.

## 2.3 Média Móvel

### 2.3.1 Média Móvel Aritmética (MMA)

A média móvel é um dos indicadores de tendência mais antigos e amplamente utilizados na análise técnica e tem como principal objetivo fornecer o valor médio da cotação de um título dentro de um determinado período de tempo. Assim para cada novo valor incluído no cálculo da média, o valor mais antigo é excluído. Na média móvel aritmética ou simples todos os valores utilizados para seu cálculo terão o mesmo peso.

A MMA é calculada adicionando-se os preços, geralmente de fechamento, para um número de períodos de tempo e dividindo-se esse valor pelo número de períodos. O MMA pode ser utilizado também sobre outros valores do título como volume, valor de abertura, valor máximo e valor mínimo.

Logo,  $MMA_H = [fech(H) + fech(H-1) + fech(H-2) + \dots + fech(H-n+1)]/n$ , onde  $n$  é o período de dias escolhido para o cálculo da MMA. Para traçar o gráfico da MMA tem-se que executar esse cálculo para cada um dos dias aos quais se deseja visualizar. Para se obter esse gráfico necessariamente tem que haver cotações nos  $n-1$  dias anteriores do qual se deseja traçar. Porém isso nem sempre é possível como nos casos de entrada de um novo título na Bolsa de Valores.

Outra questão importante no cálculo deste indicador é em relação ao número de dias escolhidos para a amostra utilizada. Os valores mais utilizados são 10, 40 e 200 dias dependendo do tipo de movimento (curto, médio ou longo prazo) no qual o investimento será baseado. Em qualquer um dos casos a MMA será interpretada como suporte nos mercados em ascensão e como resistência nos mercados em queda.

Os sinais de compra e venda de título são dados através da interseção da cotação com a o gráfico da MMA. O sinal de compra do título será dado quando o gráfico da cotação cruzar de baixo para cima o gráfico da MMA. No caso em que a cotação cruzar de cima para baixo o gráfico da MMA será dado um sinal de venda do título.

A MMA não possibilita uma antecipação nas mudanças de tendências, logo apresentarão sinais de mudança somente após o movimento ter começado. É por esse

motivo um indicador defasado, mas que apresenta resultados excelentes em mercados com tendências bem definidas. Por esse motivo alguns traders pregam que a MMA na deve ser usado em todos os momentos.

A grande proeza deste indicador esta na determinação do número de dias para que o cálculo da média seja suficientemente sensível para que os sinais não sejam muito defasados, mas ao mesmo tempo seja insensível a ponto das correções técnicas não tirarem o investidor do mercado.

### **2.3.2 Média Móvel Exponencial (MME)**

A média móvel exponencial nada mais é do que uma extensão da MMA com o objetivo de reduzir os sinais de compra e venda. A MME é uma média ponderada de observações passadas que dá maior peso aos valores mais recentes, tornando-o mais sensível aos valores mais recentes.

Ao contrário do que ocorre com a MMA, a MME dá mais importância aos valores mais novos, porém não exclui os valores mais antigos, que vão desaparecendo com o passar do tempo.

Para calcular o MME utiliza-se a fórmula  $MME_H = \text{cotação}_H * K + MME_{H-1} * (1-k)$ , onde  $k = 2/(n+1)$ .

No caso da MME os períodos de tempo mais usados para o cálculo são:

- 5 a 13 dias: curtíssimo prazo
- 14 a 25 dias: curto prazo
- 26 a 74 dias: médio prazo
- 75 a 200 dias: longo prazo

Na MME, assim como na MMA existe uma tendência de compra de título quando sua cotação cruzar de baixo para cima com a linha da MME. Também ocorre uma tendência de venda quando a cotação do título cruzar de cima para baixo a linha do gráfico MME.

No gráfico MME a sensibilidade e o número de sinais para compra e venda são inversamente proporcionais ao tamanho do período escolhido. Assim, quanto menor for o período escolhido, maior será o número de sinais gerados e sua sensibilidade. Já nos períodos maiores, sua sensibilidade e o número de sinais gerados serão menores, porém com maior confiabilidade.

## 2.4 MACD (Moving Average Convergence/Divergence)

O MACD é um popular indicador estatístico utilizado para análise técnica, desenvolvido por Gerald Appel na década de 60. O seu estudo é composto basicamente por três elementos; linha MACD, linha de sinal e histograma MACD.

A linha MACD é formada pela diferença de entre duas médias móveis exponenciais, sendo uma de longo prazo e outra de médio prazo. Normalmente a linha MACD é composta subtraindo-se o valor da MME26 do valor da MME12. Logo, o valor do  $MACD = MME12 - MME26$ . Com o resultado desse cálculo construímos uma linha gráfica que oscila acima e abaixo de zero sem qualquer limite superior ou inferior e que responde relativamente rápido as mudanças de preços.

Analizando os possíveis resultados, temos que quando o MACD for positivo, ou seja, o valor de MME12 é maior que o MME26 temos uma tendência bullish. Isso significa que as expectativas mais recentes são mais favoráveis para alta do que as anteriores. No caso de MACD negativo, ou seja, MM12 é menor que o MM26 temos uma tendência conhecida como bearish. Isso significa que as expectativas mais recentes são mais favoráveis para a baixa do que as anteriores. O caso de MACD igual a zero representa uma região não qual a oferta e a demanda (compradores/vendedores) estão em equilíbrio.

A linha de sinal, ou linha de trigger, é formada calculando-se uma média móvel exponencial de nove dias (MME9) da própria linha MACD. Com o resultado desse cálculo obtemos uma linha gráfica que responde as mudanças mais lentamente que a linha MACD. Através de relação entre a linha MACD com a linha de sinal, podemos identificar os melhores momentos para entrar (comprar) e sair (vender) do mercado.

Normalmente os sinais de compra e venda são fornecidos quando a linha MACD cruza para cima ou para baixo a linha de sinal. O cruzamento dessas linhas indica mudança nos equilíbrios de força entre compradores e vendedores. A linha MACD, que tem resposta mais rápida, reflete o consenso da massa num período de curto prazo. Já a linha de sinal, com reposta mais lenta, reflete o consenso da massa num período de longo prazo.

O sinal de compra é gerado sempre que a linha MACD cruza para cima sua linha de sinal. Quanto mais baixo ocorrer esse cruzamento no campo negativo, ou seja, abaixo da linha zero, maior será a expectativa de alta. A confirmação de compra só se da quando a linha MACD cruzar o eixo zero, saindo da região negativa.

Já o sinal de vende é gerado sempre que a linha MACD cruzar para baixo sua linha de sinal. Quanto mais alto ocorrer esse cruzamento no campo positivo, ou seja, acima da

linha zero, maior será a expectativa de baixa. A confirmação de venda só se dá quando a linha MACD cruzar o eixo zero, saindo da região positiva.

O MACD também pode ser utilizado como um oscilador, já que os valores medidos pelo indicador oscilam acima ou abaixo de uma linha tida como referencial zero, que funciona basicamente como um divisor entre mercado comprado e vendido. Este recurso possibilita identificar visualmente se um ativo está sobrecomprado ou sobrevendido, facilitando a decisão para identificar o momento certo para entrar (comprar) e sair (vender) do mercado.

Um sinal de sobrecompra é gerado sempre que as linhas se cruzarem muito acima do zero, indicando o momento de sair do mercado, assim como um sinal de sobrevendido é gerado sempre que as linhas se cruzarem muito abaixo do zero, indicando o momento de entrar no mercado.

O histograma MACD foi introduzido por Thomas Aspray em 1986 como uma forma de melhor visualizar a diferença entre linha MACD e linha de sinal, auxiliando o investidor a se orientar no mercado de ações. Seu cálculo é bem simples basta subtrair a linha de sinal da linha MACD. Portanto,  $\text{histograma MACD} = \text{linha MACD} - \text{linha de sinal}$ . Normalmente é representado por um gráfico de barras.

Uma indicação que a tendência de alta está perdendo força é quando as barras estão acima de linha zero e começam a se aproximar dela. Já uma indicação que uma tendência de baixa está perdendo força é quando ocorre o contrário e as barras que estão abaixo da linha zero começam a se aproximar dela.

Divergências entre a direção da linha MACD e a linha de cotação dos preços podem indicar uma possível reversão de tendências. Uma divergência de baixa ocorre quando a linha MACD está bem acima de zero e inicia um movimento de queda ao mesmo tempo que a linha de cotação dos preços se mantém em tendência de alta. Isso pode ser um sinal de início de tendência de baixa. Do mesmo modo que uma divergência de alta ocorre quando a linha MACD está bem abaixo de zero e inicia um movimento de subida ao mesmo tempo em que a linha de cotação dos preços se mantém em tendência de baixa. Isso pode indicar um sinal de início de tendência de alta.

É importante lembrar que o indicador MACD é bastante eficiente para acompanhar tendências. Isso significa que o indicador demora pra mostrar reversões nos preços ou oportunidades de compra e venda próximos a fundos e topos. Sua função primordial é simplesmente indicar o que está acontecendo, possibilitando que você fique junto com a tendência do mercado e conseqüentemente minimize os riscos do seu investimento.

Uma maneira de melhorar a eficiência desse indicador e minimizar os riscos inerentes aos sinais desse indicador é aguardar dois ou três dias após o sinal para confirmar a tendência.

## 2.5 DIDI Index

O indicador DIDI Index foi desenvolvido por Odir Aguiar, um conceituado analista de mercado brasileiro, baseado em médias móveis e tem como objetivo facilitar a visualização de uma “agulhada”, que indica uma reversão de tendência.

Este indicador é formado através da combinação de três média móveis aritméticas do fechamento do valor das ações, a de três, oito e vinte dias, e são usadas para traçar duas linhas. A agulhada é definida quando essas duas linhas se cruzam no ponto zero e tomam sentidos opostos. Nesse caso há uma grande possibilidade de reversão de tendência dos preços de um determinado ativo financeiro. Cruzamentos muito distantes anulam essa indicação. E quanto maior for a distância de zero, menor é a probabilidade de reversão de tendência.

O DIDI Index possui duas linhas de sinal, a linha de sinal de alta, geralmente na cor azul, e a linha de sinal de baixa, normalmente na cor vermelha. Os cálculos feitos para se obter as linhas de sinal estão descritos a seguir:

- Linha de sinal de alta =  $MMA_{20} - MMA_8$
- Linha de sinal de baixa =  $MMA_3 - MMA_8$



## **3-Redes Neurais Artificiais**

### **3.1 Introdução**

A Rede Neural Artificial é uma técnica de inteligência computacional inspirada nos neurônios biológicos e na estrutura maciçamente paralela do cérebro humano de processar informação e adquirir e armazenar conhecimento através da experiência para posterior utilização.

As Redes Neurais são capazes de lidar com dados ruidosos, incompletos e não-lineares o que as torna bem eficiente no reconhecimento e classificação de padrões, previsão de séries temporais, descoberta de conhecimento entre outras aplicações.

Devido a essas características elas são muito eficientes para tratar dos problemas encontrados para previsão futura dos valores de um ativo do mercado de ações e também podem ser aplicadas em diversas outras áreas como Energia, Telecomunicações, Medicina, Comércio, Indústria, Meio Ambiente, etc.

A grande motivação para o seu desenvolvimento foi à constatação que o cérebro processa informações de um diferente dos computadores convencionais visto que sua velocidade é um milhão de vezes mais lento que qualquer “gate” digital, porém é extremamente rápido no reconhecimento de padrões, diferente dos computadores que processam informações sequenciais extremamente rápido porém são extremamente lentos para reconhecer padrões.

Sua idéia básica consiste em um sistema de diversas unidades simples, chamados de neurônios artificiais, ligadas de maneira apropriada, gerando um comportamento extremamente interessante, complexo e não-linear determinado pela estrutura das ligações e pelos valores das interconexões.

Devido à similaridade com a estrutura do cérebro, as Redes Neurais exibem características similares ao do comportamento humano tais como: procura paralela, aprendizado, associação, generalização, abstração entre outras.

### **3.2 Conceitos Básicos**

As Redes Neurais são formadas basicamente pelos corpos dos neurônios e pelas suas interconexões.

As informações são processadas no corpo do neurônio através do somatório de suas entradas e passagem pela função de ativação, que determina o nível de ativação relativo a esse neurônio.

As interconexões entre os neurônios ou pesos sinápticos é à parte da rede onde são guardadas as informações adquiridas e determinam qual o efeito da entrada sobre o processador.

O somatório realizado no corpo do neurônio nada mais é do que a soma ponderada das entradas pelos respectivos pesos. Essas entradas são ou a entrada da rede ou as saídas da camada anterior.

A função de ativação tem como objetivo principal limitar a saída de um neurônio em um intervalo entre  $[0,1]$  ou  $[-1,1]$ .

A semelhança entre um neurônio biológico e um neurônio artificial, assim como as fórmulas do somatório ponderado das entradas pelos seus respectivos pesos sinápticos e a função de ativação pode ser vista na figura 3.1.




Figura 3.1 – Neurônio Biológico X Neurônio Artificial

As principais funções de ativação usadas nos neurônios artificiais são: degrau, tangente hiperbólica, logística e pseudo-linear.

O neurônio artificial pode também apresentar um termo chamado de bias, que tem entrada fixa em um, e serve para alterar o valor de entrada de um respectivo neurônio podendo aumentá-la ou diminuí-la de acordo com o objetivo da rede.

Normalmente as Redes Neurais apresentam três camadas de neurônios como pode ser visto na figura 3.2. A essas camadas damos os nomes de camada de entrada onde são passados os dados de entrada para a rede, a camada de saída onde é apresentado o

resultado da rede e as camadas intermediárias situadas entre as camadas de entrada. Essa camada pode ser chamada também de camada oculta, já que suas entradas e saídas permanecem dentro do sistema e por isso são desconhecidas pelo usuário.




Figura 3.2 – Estrutura de uma Rede Neural

As Redes Neurais tem topologias diferentes que se adequam a diferentes tipos de utilização. Estruturalmente o que as diferem entre si é o tipo de conexão entre os neurônios. Dependendo desta conexão recebem o nome de redes feedforward ou de redes recorrentes.

As redes feedforward são redes de uma ou mais camadas de processadores cujo o fluxo de dados se dá somente em uma direção, da entrada para a saída, sem que haja realimentação dos dados. Já as redes recorrentes também são redes de uma ou mais camadas em que há ligação entre os processadores de uma mesma camada ou com processadores de camadas anteriores gerando uma realimentação dos dados.

O desenvolvimento de uma Rede Neural é um processo de tentativa e erro que envolve a escolha da topologia, função de ativação e algoritmo de aprendizado visando fazer com que a ela tenha capacidade de generalização, isto é, deve responder corretamente não só as entradas usadas para o treinamento, assim como a entradas que nunca tenham sido apresentadas e entradas com dados faltantes e ruidosos.

### 3.3 Processos de Aprendizagem

É o processo pelo qual os pesos sinápticos de uma Rede Neural são atualizados devido à contínua estimulação do ambiente para melhorar seu desempenho, conhecido como treinamento. Quando a rede consegue generalizar a solução para uma determinada classe de problemas dizemos que ocorreu o aprendizado.

Esse treinamento ocorre através do ajuste dos pesos sinápticos, gerados pelo erro entre o valor de saída da rede para uma dada entrada e do valor desejado de saída para essa entrada.

O ajuste dos pesos sinápticos ocorre devido a um algoritmo de aprendizado que são regras definidas com o objetivo de encontrar pesos para a rede que permitam gerar saídas compatíveis com as desejadas.

Assim como o cérebro humano as Redes Neurais aprendem através da experiência e não através de programação, por isso deve-se ter bastante cuidado com o conjunto de treinamento escolhido, assim como os valores de entrada passados a rede.

Durante o processo de aprendizagem deve-se ter o cuidado de evitar o supertreinamento, e com isso perder a capacidade de generalização das Redes Neurais. Uma rede supertreinada perde a capacidade de reconhecer padrões fora do conjunto de treinamento. Para evitar essa situação a rede deve ser capaz de classificar corretamente um conjunto de teste, previamente separado, diferente do conjunto de treinamento.

Existem basicamente três tipos de aprendizado: o supervisionado, o não supervisionado e o “reinforcement learning”.

O treinamento supervisionado é aquele em que se apresentar à rede o padrão de saída desejado para que ela possa comparar com sua saída real e com isso consiga ajustar seus pesos, como mostra a figura 3.3.

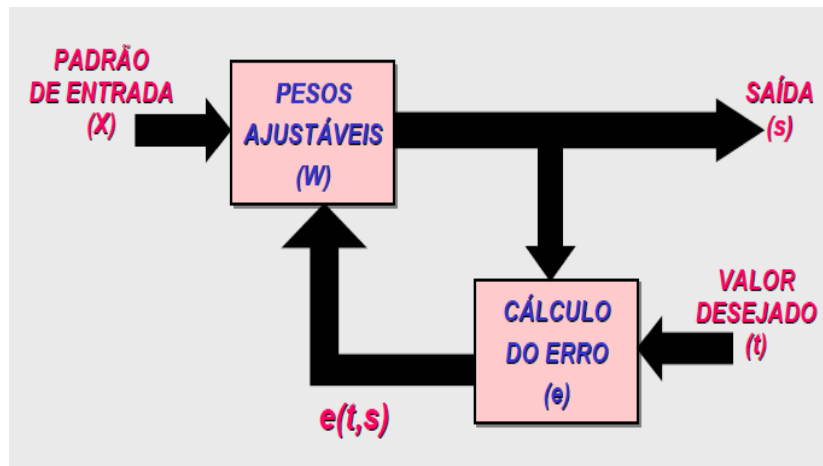


Figura 3.3 – Treinamento Supervisionado

O treinamento não-supervisionado não necessita que se passe um valor desejado de saída. O sistema consegue extrair as características do conjunto de padrões e com isso agrupá-los em classes inerentes aos dados como pode ser observado na figura 3.4. Esse tipo de aprendizado é muito utilizado em problemas de clusterização.




Figura 3.4 Treinamento Não-Supervisionado

O reinforcement learning é bastante parecido com o treinamento supervisionado pois existe um objetivo porém não temos um target definido para cada padrão. Existe um sinal de reforço que avalia a resposta com boa ou ruim que é realimentado. Nesse tipo de treinamento o objetivo é maximizar o sinal de reforço positivo e com isso aprender a realizar uma certa tarefa somente com base nos resultados de sua experiência com uma interação com o meio ambiente. É muito utilizado em robôs autômatos e aprendizado de jogos.

### 3.4 Redes Neurais Backpropagation

É uma Rede Neural feedforward de múltiplas camadas que recebe esse nome devido ao algoritmo de treinamento utilizado para atualizar os seus pesos. O desenvolvimento desse algoritmo foi um dos motivos para o ressurgimento de estudos nessa área.

O algoritmo backpropagation consiste na retropropagação do erro gerado pela comparação da saída da rede com a saída desejada visando minimizar o erro total da saída gerada pela rede. O treinamento da rede por backpropagation envolve as seguintes etapas: propagação dos dados da camada de entrada para a camada de saída da rede, o cálculo do erro, a retropropagação desse erro para as camadas intermediárias da rede e a atualização dos pesos. A figura 3.5 exemplifica o algoritmo backpropagation.




Figura 3.5 Backpropagation

Os dados apresentados à rede fluem da camada de entrada para a camada de saída, gerando um resultado. Esse resultado é comparado com o resultado desejado para que o erro seja calculado. Depois de calculado o erro os pesos da camada de saída são ajustados visando à redução do erro. Depois o erro da camada de saída é usado para ajustar os pesos da camada anterior e assim por diante até chegarem aos pesos da camada de entrada.

Nesse caso de atualização dos pesos devemos tomar cuidado com a taxa de aprendizado que será escolhida. Normalmente usa-se um valor positivo menor que um, que irá regular a intensidade com que as atualizações dos pesos ocorrerão. Taxas

muito baixas tendem a fazer com que o aprendizado seja lento e taxas muito altas fazem com que o treinamento oscile muito. Poderíamos dizer que a rede estaria aprendendo e desaprendendo o que faria com que a rede não atingisse um nível aceitável de aprendizado.

Redes Neurais com algoritmo de aprendizado backpropagation podem apresentar um termo chamado de termo de momentum. Esse termo também apresenta um valor entre zero e um que visa imprimir uma dinâmica de treinamento que possibilita ao algoritmo se livrar de mínimos locais durante seu processo de busca pelo mínimo global. Se for usado corretamente pode resultar em aprendizados mais rápidos, porém seu uso errado ocasionará instabilidade à rede.

### **3.5 Projeto de uma Rede Neural e suas Vantagens**

Para se projetar uma Rede Neural não precisamos pensar em regras, procedimentos ou fórmulas, apenas no formato dos dados de entrada e de saída.

A sua construção começa pela identificação e coleta dos dados pertinentes ao problema. Após a coleta dos dados devemos prepará-los no formato que possam ser usados pela rede. Nessa etapa devemos criar uma escala na qual todos os dados serão transformados, conhecido como normalização dos dados. Normalmente usam-se os intervalos de  $[0,1]$  ou de  $[-1,1]$ .

Depois que os dados foram normalizados dentro do intervalo escolhido, devemos separá-los em dois conjuntos, um de treinamento e outro de teste. O conjunto de treinamento será o conjunto utilizado para treinar a rede. Esse conjunto será apresentado à rede o número de vezes que for necessário para minimizar o erro da saída. O conjunto de teste será apresentado à rede somente uma vez, para testar a sua capacidade de generalização, ou seja, de responder corretamente a um grupo ao qual ela nunca tenha visto antes.

Por último devemos escolher a topologia de rede e o tipo de treinamento que será usado no modelo. Com essa escolha definida podemos desenvolver, treinar e otimizar o modelo usado. Para validar o funcionamento da rede comparamos o resultado da rede com o resultado esperado. Se o resultado estiver de acordo com a expectativa, podemos aplicar o modelo para auxiliar em problemas para os quais a rede foi treinada.

A grande vantagem das Redes Neurais é a capacidade de modelar e prever sistemas não-lineares. Além disso as redes também possuem capacidade de: lidar com dados ruidosos e faltantes, analisar e reconhecer padrões, resolver problemas sem a

necessidade de definir regras ou modelos precisos, buscar a solução dos problemas através de um método próprio de treinamento, entre outras.



## **4- Aplicações e Resultados Obtidos**

### **4.1 Tratamento dos Dados**

Os dados que serão usados nesse trabalho são dados reais de cotações diárias das ações preferenciais da Petrobras (PETR4), referentes ao período de 5 abril de 1999 até 24 de maio de 2010. Com estes dados foram calculados os diversos indicadores utilizados, como para o calculo dos indicadores são utilizados dados do passado, o conjunto de dados disponíveis para a rede neural foi ligeiramente diminuído.

Os dados foram divididos em três conjuntos distintos de treino, validação e teste. O conjunto de treino abrange o período de 19 de maio de 2003 até 28 de agosto de 2008. O conjunto de validação abrange o período de 29 de agosto de 2008 até 28 de outubro de 2009. Já o conjunto de teste abrange o período de 29 de outubro de 2009 até 24 de maio de 2010.

Após a divisão em três conjuntos distintos, os dados foram normalizados de duas formas diferentes. Alguns foram normalizados de menos um até um e outros foram normalizados apenas de zero até um. Essa normalização tem como objetivo diminuir a influência que alguns valores possam causar sobre os outros devido ao seu valor mais alto em relação aos outros.

Os dados serão passado para a rede através de um arquivo gerado pelo excel, onde cada linha representa um padrão de entrada diferente. Já as colunas representam cada indicador passado para a rede excetuando-se a última, que representa o padrão de saída desejado.

### **4.2 Seleção das Variáveis**

Uma decisão de extrema importância, que irá influenciar diretamente no aprendizado e aplicabilidade da rede neural é a seleção de variáveis. São com esses dados de entradas que a rede neural irá realizar seu aprendizado, portanto essa etapa tem uma grande influência nos resultados que serão obtidos.

Nesse trabalho, os indicadores passados como variáveis de entrada e que influenciarão diretamente na saída obtida serão: preço de abertura, preço máximo, preço mínimo, preço de fechamento, indicador IFR14, linha MACD, linha sinal, histograma MACD, MMA10, MMA10 deslocada de um dia para trás, DIDI index (20-8), DIDI index (3-8), cruzamento subindo ou descendo das linhas de DIDI index, banda de Bollinger superior, banda de Bollinger inferior e se o fechamento ocorreu dentro ou fora das bandas, MME9. Como saída será binaria indicando um (1) se o retorno nos próximos quatro dias foi maior que quatro por cento (4%) e zero (0) se o retorno for menor.

A figura 4.1 apresenta a série de preços das cotações das ações preferenciais da Petrobras (PETR4).




Figura 4.1 Série de preços das ações preferenciais da Petrobras

### 4.3 Arquitetura Proposta

Para obter o melhor desempenho de uma rede neural, é necessário fazer uma série de escolhas nem sempre triviais. As principais escolhas a serem feitas são: topologia, algoritmo de treinamento, função de ativação do neurônio, taxa de aprendizado e momento e o número de épocas.

A arquitetura proposta neste trabalho será uma rede neural feedforward, treinada pelo algoritmo backpropagation para realizar a estratégia que indica o momento de compra das ações da Petrobras PETR4 de forma que lhe garanta um retorno mínimo de 4%, o modelo visa fornecer ao investidor uma ferramenta que irá auxiliá-lo a tomar uma decisão mais segura.

A camada de entrada será formada por dezenove entradas, uma para cada indicador utilizado pela rede. O número de neurônios na camada escondida será variado durante os treinos visando obter um resultado satisfatório. A camada de saída será composta por um neurônio que representa o resultado desejado, nesse caso se o preço da ação terá uma alta de quatro por cento nos próximos quatro dias, indicado como um.

Para a obtenção do melhor resultado, será modificado além do número de neurônios na camada escondida, o número de épocas e as taxas de aprendizado e de momento.

Para os neurônios da camada escondida será usada a função tangente hiperbólica como função de ativação. Já para a camada de saída será usada uma função linear. A saída da rede neural será processada da seguinte forma: será considerado um se a saída for maior que 0,6 e zero se saída for menor que 0,4. Será considerado indiferente os resultados entre essa faixa.

## 5-Resultados Obtidos

Na tabela abaixo são apresentados os resultados obtidos durante o treinamento da rede nos diferentes experimentos realizados.

<b>Camada Escondida</b>	<b>Taxa de aprendizado</b>	<b>Termo de momento</b>	<b>Número de treinos</b>	<b>Erro do treinamento MAPE (%)</b>
6	0,7	0,2	1000	0,291
6	0,7	0,7	3000	0,192
8	0,5	0,2	2000	0,155
8	0,5	0,7	4000	0,097
10	0,7	0,2	2000	0,272
10	0,7	0,7	4000	0,171
10	0,5	0,7	4000	0,093
12	0,5	0,2	2000	0,143
12	0,7	0,7	4000	0,165
15	0,5	0,5	3000	0,139
15	0,5	0,2	5000	0,126
15	0,5	0,7	5000	0,089
18	0,5	0,5	3000	0,124
18	0,5	0,7	4000	0,061
18	0,7	0,7	4000	0,173
21	0,5	0,8	3000	0,179
21	0,3	0,5	3000	0,205
25	0,3	0,7	3000	0,199
25	0,5	0,5	4000	0,186

Como podemos observar pela tabela de treinamentos acima, vemos que a rede neural que apresentou o melhor resultado de todos os experimentos foi a rede neural composta por dezoito neurônios na camada escondida, com 0,5 de taxa de aprendizado, com 0,6 de termo de momento e quatro mil treinos.

Seguindo a estratégia sugerida pela rede neural um investidor deverá realizar uma compra de N ações da PETR4 cada vez que a rede neural de uma indicação de compra, devendo vender as ações quatro dias depois da compra, se uma nova indicação não for dada. No caso da rede neural indicar uma nova compra antes do cumprimento dos quatro dias o investidor aumentará o número de ações (acumula ações) comprando mais N ações vendendo tudo depois de quatro dias se uma nova indicação não for dada.

Analisando os resultados da melhor rede neural descrita acima observamos que essa rede neural nos deu 11 indicações de compra num período de 137 dias de negociação, resultando em acumulação de ações em algumas delas e, por conseguinte foram realizadas só 5 vendas para fechar as posições compradas.

Na figura 5.1 é apresentado o gráfico de cotações dos preços da PETR4 em formato de candlestick que representa preço de abertura, máximo, mínimo e preço de fechamento do dia, nele são apresentadas as indicações de compra dadas pela rede neural (seta azul para acima) e a venda das ações é realizada apos quatro dias sem outra indicação (seta vermelha para abaixo).




Figura 5.1 Indicações de compra fornecidas pela rede neural

Na tabela abaixo é apresentada a tabela com os retornos obtidos com cada indicação de compra de ações sugerida pela rede neural.

Indicação	Retorno
1	7.4%
2	7.0%
3	6.0%
4	3.7%
5	4.6%
6	10.0%
7	9.3%
8	7.6%
9	6.3%
10	5.1%
11	4.0%

Observa-se que no período de 137 dias o investidor obteve um retorno total de 70,9% seguindo a estratégia de compra sugerida pela rede neural.

## 6-Conclusões

O comportamento futuro dos valores de uma ação para determinar estratégias eficientes de compra por redes neurais atrai o interesse tanto de pequenos investidores como o de investidores profissionais. Devido ao avanço tecnológico e o desenvolvimento de computadores com grande capacidade de processamento foi possível desenvolver modelos capazes de prever o comportamento dos valores de um determinado ativos financeiro.

Visando desenvolver uma ferramenta que superasse as dificuldade encontradas nesse problema e que auxiliasse o investidor em sua tomada de decisão, tornado-a mais segura, foi desenvolvido um modelo e implementado usando redes neurais devido a sua grande capacidade de modelar problemas não-lineares.

Observando os resultados obtidos nesse trabalho, podemos perceber que uma rede neural bem desenvolvida consegue estimar a tendência de um ativo financeiro, aproximando-se do seu comportamento real. Com isso podemos perceber que a vida tanto dos pequenos investidores quanto dos investidores profissionais pode ser facilitada com o uso apropriado de uma rede, aumentando seu ganho, agilizando sua tomada de decisão e diminuindo seu risco. Como foi visto nos resultados obtidos onde foi conseguido um lucro acumulado de 70,9% para um período de 137 dias, sendo que todas as indicações dadas pela rede neural foram lucrativas, onde a variação do lucro foi de 3,9% até 10%.

Devido a grande aplicabilidade de inteligência computacional a problemas ligados ao mercado financeiro podemos citar como possibilidades de pesquisa para futuros trabalhos:

- A implementação de uma rede neural com uma topologia diferente, empregando diferentes algoritmos de aprendizado e funções de ativação dos neurônios, assim como uma rede com duas camadas escondidas ao invés de somente uma.
- O uso de um sistema de previsão através de lógica fuzzy ao invés de uma rede neural para comparação dos resultados obtidos.
- O uso de algoritmo genético em conjunto com um sistema de previsão de valor futuro para a obtenção de uma carteira ótima de investimento.