01-preprocessing_data_exploration

March 21, 2021

1 Pré-processamento e Exploração dos Dados

Aqui vou explorar as características das série temporal - Plotar gráficos de box-plot, histogramas e de linhas por anos - Analisar - distribuição - sazonalidade - tendência - auto-correlação - Teste de estacionariedade

1.1 Importações

```
[1]: # Data analysis and data wrangling
     import numpy as np
     import pandas as pd
     # Metrics
     import statistics
     # Plotting
     from statsmodels.graphics.tsaplots import plot_acf
     from statsmodels.graphics.tsaplots import plot_pacf
     from pandas.plotting import autocorrelation_plot
     from pandas.plotting import lag_plot
     import seaborn as sns
     import matplotlib.pyplot as plt
     from matplotlib import pyplot
     # statsmodels
     from statsmodels.tsa.stattools import adfuller
     from statsmodels.tsa.stattools import acf, pacf
     from statsmodels.tsa.seasonal import seasonal_decompose
     import statsmodels.tsa.api as smt
     import statsmodels.api as sm
     import statsmodels.tsa as tsa
     import statsmodels.api as sm
     # Other
     from IPython.display import Image
     import warnings
```

```
import pprint
import datetime
import os
```

1.2 Preparação do diretório principal

```
def prepare_directory_work(end_directory: str='notebooks'):
    # Current path
    curr_dir = os.path.dirname (os.path.realpath ("__file__"))

if curr_dir.endswith(end_directory):
    os.chdir('...')
    return curr_dir

return f'Current working directory: {curr_dir}'
```

```
[3]: prepare_directory_work(end_directory='notebooks')
```

[3]: '/home/campos/projects/tcc/notebooks'

1.3 Formatação das células

1.4 Carregamento dos dados

Tokenization took: 0.53 ms

Type conversion took: 2.63 ms

Parser memory cleanup took: 0.01 ms

CPU times: user 6.34 ms, sys: 3.22 ms, total: 9.56 ms

Wall time: 11.4 ms

```
[7]: df_vale3.head(15)
```

```
[7]:
                 Date
                          Price
                                      Open
                                                                  Vol. Change %
                                                High
                                                           Low
         Jun 19, 2020 55.170000 56.330000 56.600000 54.710000
     0
                                                                37.86M
                                                                          -1.78\%
         Jun 18, 2020 56.170000 56.300000 56.540000 55.610000
                                                                25.69M
                                                                          -0.05%
     1
     2
         Jun 17, 2020 56.200000 55.490000 56.440000 55.150000
                                                                27.57M
                                                                          1.46%
     3
         Jun 16, 2020 55.390000 55.490000 55.500000 54.220000
                                                                29.17M
                                                                          2.80%
         Jun 15, 2020 53.880000 52.500000 54.430000 52.130000
                                                                27.32M
                                                                          0.90%
     4
     5
         Jun 12, 2020 53.400000 53.710000 54.050000 51.980000
                                                                31.18M
                                                                         -1.48\%
     6
         Jun 10, 2020 54.200000 54.910000 55.200000 53.760000
                                                                24.19M
                                                                         -1.44%
     7
         Jun 09, 2020 54.990000 54.160000 54.990000 54.120000
                                                                          0.38%
                                                                19.61M
         Jun 08, 2020 54.780000 54.980000 55.650000 53.980000
     8
                                                                27.19M
                                                                          0.31%
         Jun 05, 2020 54.610000 56.390000 56.700000 54.340000
                                                                          -1.89%
                                                                39.64M
         Jun 04, 2020 55.660000 53.720000 55.700000 53.520000
                                                                37.38M
                                                                          3.73%
         Jun 03, 2020 53.660000 53.420000 54.330000 53.390000
                                                                          0.45%
     12
         Jun 02, 2020 53.420000 53.800000 53.800000 53.000000
                                                                25.42M
                                                                          0.00%
         Jun 01, 2020 53.420000 52.820000 53.850000 52.500000
     13
                                                                27.01M
                                                                          0.79%
        May 29, 2020 53.000000 51.400000 53.000000 51.060000
                                                                92.24M
                                                                          5.81%
```

1.5 Análise Exploratória

- 1. Colunas: Date (eixo x): data dos dados Price (eixo y): é o preço de fechamento. O que será previsto Open: preço de abertura High: preço máximo atingido Low: preço mínimo atingido Vol.: volume de ações negociadas Change %: porcentagem de alteração em relação ao dia anterior
- 2. Contexto: Mercado de ações VALE3

```
Formato dos dados
```

```
[8]: print("Dataframe:\n{} rows\n{} columns".format(df_vale3.shape[0], df_vale3.shape[1]))
```

Dataframe:

2495 rows

7 columns

Colunas

```
[9]: list_columns = (df_vale3.columns).tolist()

print("-"*25, "List Columns", "-"*25, end='\n')
display(list_columns)
```

```
----- List Columns
```

```
['Date', 'Price', 'Open', 'High', 'Low', 'Vol.', 'Change %']
```

[10]: df_vale3.info()

<class 'pandas.core.frame.DataFrame'>
RangeIndex: 2495 entries, 0 to 2494
Data columns (total 7 columns):

#	Column	Non-Null Count	Dtype
0	Date	2495 non-null	object
1	Price	2495 non-null	float64
2	Open	2495 non-null	float64
3	High	2495 non-null	float64
4	Low	2495 non-null	float64
5	Vol.	2495 non-null	object
6	Change %	2495 non-null	object
	67+ 6	1(1) -1(2)	

dtypes: float64(4), object(3)

memory usage: 136.6+ KB

```
[11]: df_vale3.nunique()
```

```
[11]: Date 2495
Price 1845
Open 1816
High 1852
```

```
dtype: int64
[12]: def show_measures_location(df: 'dataframe', type_descr: 'list') -> None:
          Function get measures localization + total col + % type columns
          Handler when type data not exists
          Args:
          type_descr
              np.number, np.object -> return summary statistic with all columns
              np.number
                                    -> return summary statistic numerical columns
              np.object
                                    -> return summary statistic object columns
          11 11 11
              col = (df.describe(include=type_descr).columns) # pandas.core.indexes.
       \rightarrow base. Index
          except ValueError:
              print(f'Dataframe not contains {type descr} columns !', end='\n\n')
          else:
              list_col = col.tolist()
              percentage = (len(list_col) / df.shape[1]) * 100
              print("-"*25, "MEASURES OF LOCALIZATION", "-"*25, end='\n\n')
              print(f"TOTAL columns {type_descr}: {len(list_col)}")
              print("PERCENTAGE {} in dataframe: {:3.4} %".format(type_descr,__
       →percentage))
              return df.describe(include=type_descr)
[13]: show_measures_location(df=df_vale3,
                             type_descr=[np.number, np.object])
                ----- MEASURES OF LOCALIZATION -----
     TOTAL columns [<class 'numpy.number'>, <class 'object'>]: 7
     PERCENTAGE [<class 'numpy.number'>, <class 'object'>] in dataframe: 100.0 %
[13]:
                      Date
                                 Price
                                              Open
                                                          High
                                                                       Low
                                                                             Vol. \
                      2495 2495.000000 2495.000000 2495.000000 2495.000000
      count
                                                                             2495
                                                                             1339
      unique
                      2495
                                   nan
                                               nan
                                                           nan
      top
              Apr 25, 2018
                                   nan
                                               nan
                                                           nan
                                                                       nan 3.99M
                                   nan
     freq
                                               nan
                                                           nan
                                                                       nan
     mean
                       NaN
                             35.801788
                                         35.828188
                                                     36.316914
                                                                 35.315695
                                                                              NaN
                             12.277343
                                         12.279942
                                                     12.344400
                                                                 12.184122
                                                                              NaN
      std
                       \mathtt{NaN}
```

Low

Vol.

Change %

1845

1339

927

```
8.600000
                                                         9.060000
      min
                        NaN
                                            8.750000
                                                                      8.600000
                                                                                   NaN
      25%
                        {\tt NaN}
                               26.880000
                                           26.930000
                                                        27.340000
                                                                     26.605000
                                                                                   NaN
      50%
                        NaN
                                                                                   NaN
                               36.880000
                                           36.870000
                                                        37.420000
                                                                     36.300000
      75%
                        NaN
                               46.355000
                                           46.330000
                                                        46.830000
                                                                     45.730000
                                                                                   NaN
      max
                        NaN
                               62.200000
                                           62.200000
                                                        62.420000
                                                                     60.480000
                                                                                   NaN
             Change %
                  2495
      count
                   927
      unique
      top
                 0.00%
                    20
      freq
      mean
                   NaN
      std
                   NaN
                   NaN
      min
      25%
                   NaN
      50%
                   NaN
      75%
                   NaN
      max
                   NaN
[14]:
     df_vale3.mode(dropna=False, numeric_only=True)
[14]:
            Price
                        Open
                                   High
                                               Low
      0 27.430000 51.000000 38.150000 17.650000
      1
                         nan 44.330000
              nan
                                               nan
      2
                         nan 52.090000
              nan
                                               nan
      3
                         nan 53.120000
              nan
                                               nan
[15]: df_vale3.median()
[15]: Price
              36.880000
      Open
              36.870000
      High
              37.420000
      Low
               36.300000
      dtype: float64
     Valores ausentes
[16]: df_vale3.isnull().any()
[16]: Date
                   False
      Price
                   False
      Open
                   False
      High
                   False
                   False
      Low
      Vol.
                   False
```

Change %

dtype: bool

False

Valores duplicados

```
[17]: df_vale3.duplicated().any()
```

[17]: False

1.6 Pré-processamento

A análise da ST é univariada, ou seja, somente a coluna **price** em relação ao tempo que será prevista. Isto vai garantir uma melhor comparação entre os modelos estatísticos, de aprendizado de máquina e aprendizado profundo.

Remover colunas desnecessárias

```
[19]: df_vale3.drop(['Open', 'High', 'Low', 'Vol.', 'Change %'], axis=1, inplace=True)
```

Todas as colunas em letras minúsculas

```
[20]: df_vale3.columns = map(str.lower, df_vale3.columns)
print(df_vale3.columns)
```

Index(['date', 'price'], dtype='object')

lista de colunas

```
[21]: list_columns = []
list_columns = df_vale3.columns
list_columns
```

[21]: Index(['date', 'price'], dtype='object')

1.6.1 Formatação das Colunas

Data


- Transforma o formato da data (Jun 19, 2020) em (2020-06-19)
- Transforma a o tipo da coluna date para datetime64

```
[22]: df_vale3['date'] = pd.to_datetime(df_vale3['date'])
      df_vale3 = df_vale3.iloc[::-1]
[23]: df_vale3.head(10)
[23]:
                 date
                          price
     2494 2010-05-20 39.790000
      2493 2010-05-21 42.460000
     2492 2010-05-24 42.020000
     2491 2010-05-25 42.390000
      2490 2010-05-26 42.170000
     2489 2010-05-27 44.820000
      2488 2010-05-28 44.420000
      2487 2010-05-31 45.370000
      2486 2010-06-01 44.390000
      2485 2010-06-02 45.320000
[24]: df_vale3.info()
     <class 'pandas.core.frame.DataFrame'>
     RangeIndex: 2495 entries, 2494 to 0
     Data columns (total 2 columns):
          Column Non-Null Count Dtype
                  2495 non-null
      0
          date
                                  datetime64[ns]
                  2495 non-null
                                  float64
          price
     dtypes: datetime64[ns](1), float64(1)
     memory usage: 39.1 KB
     1.7 Data como índice
[25]: df_vale3_date_index = df_vale3
      df_vale3_date_index.index.names = ['date']
      df_vale3_date_index.index = df_vale3['date']
      df_vale3_date_index.index = pd.to_datetime(df_vale3.index)
      print(df_vale3_date_index.index.freq)
      print(df_vale3_date_index.index)
     DatetimeIndex(['2010-05-20', '2010-05-21', '2010-05-24', '2010-05-25',
                    '2010-05-26', '2010-05-27', '2010-05-28', '2010-05-31',
                    '2010-06-01', '2010-06-02',
                    '2020-06-05', '2020-06-08', '2020-06-09', '2020-06-10',
                    '2020-06-12', '2020-06-15', '2020-06-16', '2020-06-17',
                    '2020-06-18', '2020-06-19'],
                   dtype='datetime64[ns]', name='date', length=2495, freq=None)
```

```
[26]: date price
date
2010-05-20 2010-05-20 39.790000
2010-05-21 2010-05-21 42.460000
2010-05-24 2010-05-24 42.020000
2010-05-25 2010-05-25 42.390000
2010-05-26 2010-05-26 42.170000
```

1.8 Box Plot

```
[27]: def plot_box_plot(df: 'dataframe', data_set_name: str, xlim=None):
          Creates a seaborn boxplot including all dependent
          Arqs:
          data_set_name: Name of title for the boxplot
          xlim: Set upper and lower x-limits
          Returns:
          Box plot with specified data_frame, title, and x-limits
          fig, ax = plt.subplots(figsize=(18, 10))
          if xlim is not None:
              plt.xlim(*xlim)
          plt.title(f"Horizontal Boxplot {data_set_name}")
          plt.ylabel('Dependent Variables')
          plt.xlabel('Measurement x')
          ax = sns.boxplot(data = df,
                          orient = 'h',
                          palette = 'Set2',
                          notch = False, # box instead of notch shape
                          sym = 'rs') # red squares for outliers
          plt.show()
```



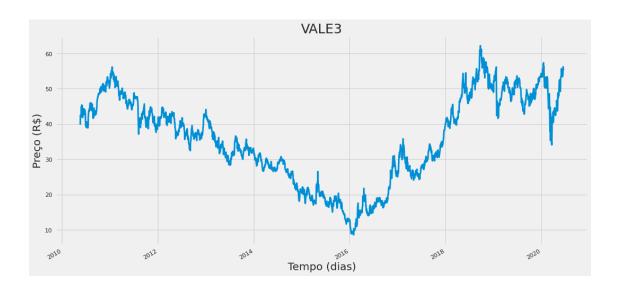
1.9 Análise dos componentes da ST

- distribuição
- sazonalidade
- tendência
- ruídos

Distribuição

```
[29]: img_vale3_distr_line = df_vale3_date_index['price'].plot(linewidth=3)

plt.title(f'VALE3', fontsize=25)
plt.xlabel("Tempo (dias)", fontsize=20)
plt.ylabel("Preço (R$)", fontsize=20)
plt.grid(True)
```

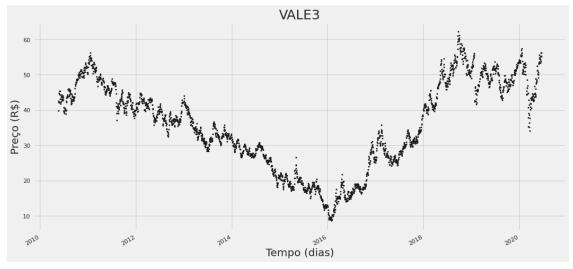


```
[30]: save_image(img=img_vale3_distr_line, name='img_vale3_distr_line')

[30]: 'Image img_vale3_distr_line saved.'

[31]: img_vale3_distr_scatter = df_vale3_date_index['price'].plot(style='k.')

plt.title(f'VALE3', fontsize=25)
 plt.xlabel("Tempo (dias)", fontsize=20)
 plt.ylabel("Preço (R$)", fontsize=20)
 plt.grid(True)
```



```
[32]: save_image(img=img_vale3_distr_scatter, name='img_vale3_distr_scatter')
```

[32]: 'Image img_vale3_distr_scatter saved.'

NOTAS

- Houve uma grande tendência de baixa, començando após alcançar o topo e durou aproximadamente 500 dias.
- Depois da tendência de baixa alvançar o fundo houve reversão de começando um ciclo de alta.
- No momento aparenta estar em fase de consolidação.

1.10 Decomposição da Série Temporal

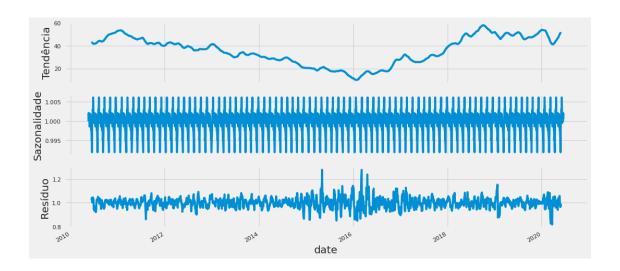
- O objetivo é decompor a ST
- A ST aparenta ter duas tendências sendo os dois casos uma tendência linear do que exponencial, então a decomposição será additive

```
[34]: fig, axes = plt.subplots(ncols=1, nrows=3, sharex=True)

axes[0].set_ylabel('Tendência', fontsize=20)
axes[1].set_ylabel('Sazonalidade', fontsize=20)
axes[2].set_ylabel('Resíduo', fontsize=20)
axes[2].set_xlabel('Tempo dias', fontsize=20)

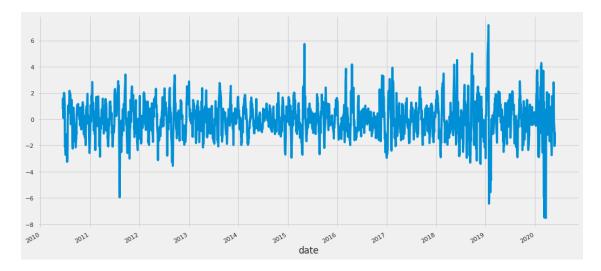
decomposition_add.trend.plot(ax=axes[0])
decomposition_add.seasonal.plot(ax=axes[1])
decomposition_add.resid.plot(ax=axes[2])
```

[34]: <AxesSubplot:xlabel='date', ylabel='Residuo'>




```
[35]: df_vale3_without_trend = df_vale3['price'] - trend img_df_vale3_without_trend = df_vale3_without_trend.plot() save_image(img=img_df_vale3_without_trend, name='img_df_vale3_without_trend')
```

[35]: 'Image img_df_vale3_without_trend saved.'




[36]: 'Image img_df_vale3_without_seasonal saved.'



```
[37]: df_vale3_without_resid = df_vale3['price'] - residual df_vale3_without_resid = df_vale3_without_resid.plot() save_image(img=df_vale3_without_resid, name='df_vale3_without_resid')
```





NOTAS:

A decomposição da ST demonstra: - Ocorreram 2 grandes tendências e nos últimos anos o preço não apresenta uma tendência evidente. - A sazonalidade ocorre de 30 em 30 dias. - O que se pode notar é que de 2018 em diante os resíduos aumentaram. Neste mesmo período a ST não apresentou uma tendência clara.

1.11 Auto-correlação

Modelos autoregressivos como ARIMA, supõem que as observações anteriores são úteis para prever o valor da próxima etapa de tempo. Quanto mais forte a correlação entre a variável de saída e uma variável defasada específica, mais peso o modelo de auto-regressão pode colocar nessa variável.

NOTAS:

- A correlação é calculada entre a variável e ela mesma nas etapas de tempo anteriores, por isso o nome autocorrelação.
- Calcular a correlação também podem ajudar escolher as variáveis de atraso serão úteis em um modelo e quais não serão.
- Se as variáveis de atraso mostrarem baixa ou nenhuma correlação com a variável de saída, a série temporal pode não ser previsível.
- Usei Pearson

 $\label{eq:wiki} \begin{tabulum}{ll} wiki análise de autocorrelação é uma ferramenta matemática para encontrar padrões repetitivos, como a presença de um sinal periódico obscurecido por ruído ou a identificação da frequência fundamental ausente em um sinal implícito por suas frequências harmônicas . É frequentemente usado no processamento de sinais para analisar funções ou séries de valores, como sinais no domínio do tempo . \\ \end{tabulum}$


```
[38]: df_vale3_date_index['price'].autocorr(lag=1)

[38]: 0.9972513584845024
```

```
[39]: img_df_vale3_autocorr_1 = lag_plot(df_vale3_date_index['price'], lag=1) save_image(img=img_df_vale3_autocorr_1, name='img_df_vale3_autocorr_1')
```

c argument looks like a single numeric RGB or RGBA sequence, which should be avoided as value-mapping will have precedence in case its length matches with *x* & *y*. Please use the *color* keyword-argument or provide a 2-D array with a single row if you intend to specify the same RGB or RGBA value for all points.

[39]: 'Image img_df_vale3_autocorr_1 saved.'




[40]: df_vale3_date_index['price'].autocorr(lag=30)

[40]: 0.9459357661702158

[41]: img_df_vale3_autocorr = lag_plot(df_vale3_date_index['price'], lag=30) save_image(img=img_df_vale3_autocorr, name='img_df_vale3_autocorr')

c argument looks like a single numeric RGB or RGBA sequence, which should be avoided as value-mapping will have precedence in case its length matches with *x* & *y*. Please use the *color* keyword-argument or provide a 2-D array with a single row if you intend to specify the same RGB or RGBA value for all points.

[41]: 'Image img_df_vale3_autocorr saved.'

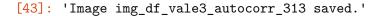


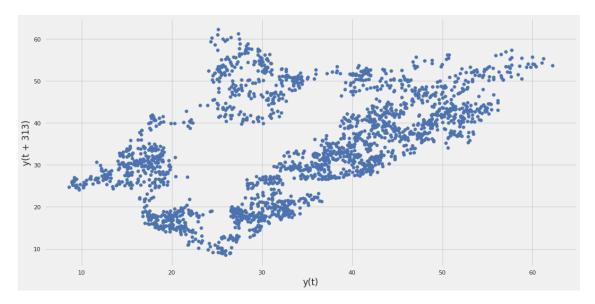
```
[42]: df_vale3_date_index['price'].autocorr(lag=313)
```

[42]: 0.5017662028027128

```
[43]: img_df_vale3_autocorr_313 = lag_plot(df_vale3_date_index['price'], lag=313) save_image(img=img_df_vale3_autocorr_313, name='img_df_vale3_autocorr_313')
```

c argument looks like a single numeric RGB or RGBA sequence, which should be avoided as value-mapping will have precedence in case its length matches with *x* & *y*. Please use the *color* keyword-argument or provide a 2-D array with a single row if you intend to specify the same RGB or RGBA value for all points.





```
[44]: df_vale3_date_index['price'].autocorr(lag=314)
```

[44]: 0.49925706901064987

Até 314 dias ainda possuem correlação.

```
Visualização da variável lag
```

```
[45]: df_vale3_original_lag_30 = pd.concat([df_vale3_date_index['price'], df_vale3_date_index['price'].shift(30)],__ 
axis=1)
```

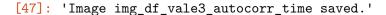
```
[46]: df_vale3_original_lag_30.head(50)
```

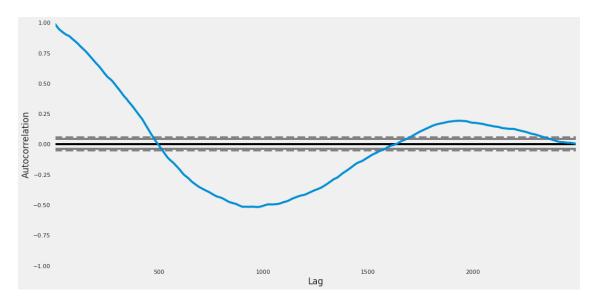
[46]:	doto	price	price
	date	20 700000	
	2010-05-20 2010-05-21		nan
	2010-05-21		nan
	2010-05-24		nan
			nan
	2010-05-26 2010-05-27		nan
	2010-05-27		nan
	2010-05-20		nan nan
	2010-05-31		nan
	2010-06-02		nan
	2010-06-04		nan
	2010-06-07		nan
	2010-06-08		nan
	2010-06-09		nan
	2010-06-10		nan
	2010-06-11	43.730000	nan
	2010-06-14		nan
	2010-06-15		nan
	2010-06-16		nan
	2010-06-17	43.050000	nan
	2010-06-18		nan
	2010-06-21		nan
	2010-06-22		nan
	2010-06-23		nan
	2010-06-24	43.100000	nan
	2010-06-25	43.630000	nan
	2010-06-28	42.810000	nan
	2010-06-29	40.740000	nan
	2010-06-30	39.610000	nan
	2010-07-01	39.780000	nan
	2010-07-02	39.580000	39.790000
	2010-07-05	39.020000	42.460000
	2010-07-06	39.510000	42.020000
	2010-07-07	40.460000	42.390000
	2010-07-08	40.600000	42.170000
	2010-07-12	40.000000	44.820000
	2010-07-13	40.070000	44.420000
	2010-07-14	40.080000	45.370000
	2010-07-15	39.760000	44.390000
	2010-07-16	38.880000	45.320000
	2010-07-19	39.970000	43.180000
	2010-07-20	42.230000	41.830000
	2010-07-21	42.470000	42.270000
	2010-07-22	43.370000	42.430000
	2010-07-23	43.710000	43.200000

```
2010-07-26 43.730000 43.730000
2010-07-27 43.550000 43.750000
2010-07-28 44.320000 44.380000
2010-07-29 43.920000 43.830000
2010-07-30 44.050000 43.050000
```

Podemos ver um grande grupo de observações ao longo de uma linha diagonal, mostrando claramente uma relação ou alguma correlação.

```
[47]: img_df_vale3_autocorr_time = autocorrelation_plot(df_vale3_date_index['price']) save_image(img=img_df_vale3_autocorr_time, name='img_df_vale3_autocorr_time')
```





Os intervalos de confiança são de 95% e 99% sugerindo que os valores de correlação fora desse intervalo são muito provavelmente uma correlação e não um acaso estatístico.

1.12 Estacionariedade


É preciso garantir que os dados são estacionários. Significa que a série temporal possui um comportamento ao longo do tempo e que possui uma alta probabilidade de seguir este mesmo comportamento no futuro.

Visualmente a série não é estacionária. Para garantir o comportamento dessa série vou plotar as estatíticas de rolagem(ma, var) e fazer o teste de Dickey-Fuller.

Então neste teste avalio duas hipóteses: - Hipótese nula (H0) : não é estacionária. Tem alguma estrutura dependente do tempo. - Hipótese alternativa (H1) : é estacionária. Não tem estrutura dependente do tempo.

```
[48]: def test_stationarity(timeseries):
          # determing rolling statistics
          rolmean = timeseries.rolling(window=30, center=False).mean()
          rolstd = timeseries.rolling(window=30, center=False).std()
          # plot rolling statistics:
          orig = plt.plot(timeseries, color='blue',label='Original')
          mean = plt.plot(rolmean, color='red', label='Rolling Mean')
          std = plt.plot(rolstd, color='black', label = 'Rolling Std')
          plt.legend(loc='best')
          plt.title('Rolling Mean & Standard Deviation')
          plt.show(block=False)
          # perform Dickey-Fuller test:
          print('Results of Dickey-Fuller Test:')
          dftest = adfuller(timeseries, autolag=None)
          dfoutput = pd.Series(dftest[0:4], index=['Test Statistic','p-value','Lags_\'
       →Used','Number of Observations Used'])
          for key,value in dftest[4].items():
              dfoutput['Critical Value (%s)'%key] = value
          print(dfoutput)
```

[49]: test_stationarity(df_vale3['price'])



```
Results of Dickey-Fuller Test:
Test Statistic -0.929286
```

p-value	0.778175
Lags Used	27.000000
Number of Observations Use	d 2467.000000
Critical Value (1%)	-3.433003
Critical Value (5%)	-2.862712
Critical Value (10%)	-2.567394


dtype: float64

NOTES

- Usado autolag='AIC' para a própia função determinar o lag, escolhendo o menor valor observado.
- Test Statistic > Critical Value (1%), então a H0 é aceita, ou seja, não se tem estacionariedade na ST explorada
- Neste caso se faz necessário deixar a ST estacionária!

Estacionariedade por Decomposição

[50]: residual residual.dropna(inplace=True) test_stationarity(residual)



Results of Dickey-Fuller Test:

Test Statistic	-12.432177
p-value	0.000000
Lags Used	27.000000
Number of Observations Used	2437.000000
Critical Value (1%)	-3.433036
Critical Value (5%)	-2.862727
Critical Value (10%)	-2.567402

dtype: float64

2 Criação de Novas Características

```
[51]: cols = ['data', 'preco', 'residuos', 'tendencia', 'sazonalidade']
[52]: df = pd.DataFrame(columns=cols)
      df.head()
[52]: Empty DataFrame
      Columns: [data, preco, residuos, tendencia, sazonalidade]
      Index: []
[53]: df['data'] = df_vale3['date']
      df.head()
[53]:
                        data preco residuos tendencia sazonalidade
      date
      2010-05-20 2010-05-20
                               NaN
                                        NaN
                                                   NaN
                                                                 NaN
      2010-05-21 2010-05-21
                               NaN
                                        NaN
                                                   NaN
                                                                 NaN
      2010-05-24 2010-05-24
                               NaN
                                        NaN
                                                   NaN
                                                                 NaN
      2010-05-25 2010-05-25
                               NaN
                                        NaN
                                                   NaN
                                                                 NaN
      2010-05-26 2010-05-26
                               NaN
                                        NaN
                                                   NaN
                                                                 NaN
[54]: df['preco'] = df_vale3['price']
      df.head()
[54]:
                        data
                                 preco residuos tendencia sazonalidade
      date
      2010-05-20 2010-05-20 39.790000
                                             NaN
                                                       NaN
                                                                     NaN
      2010-05-21 2010-05-21 42.460000
                                            NaN
                                                       NaN
                                                                     NaN
      2010-05-24 2010-05-24 42.020000
                                            NaN
                                                       NaN
                                                                     NaN
      2010-05-25 2010-05-25 42.390000
                                             NaN
                                                       NaN
                                                                     NaN
      2010-05-26 2010-05-26 42.170000
                                             NaN
                                                       NaN
                                                                     NaN
[55]: df['tendencia'] = trend.values
      df.head(20)
[55]:
                        data
                                 preco residuos tendencia sazonalidade
      date
      2010-05-20 2010-05-20 39.790000
                                             NaN
                                                        nan
                                                                      NaN
      2010-05-21 2010-05-21 42.460000
                                             NaN
                                                                      NaN
                                                        nan
      2010-05-24 2010-05-24 42.020000
                                             NaN
                                                                      NaN
                                                        nan
      2010-05-25 2010-05-25 42.390000
                                             {\tt NaN}
                                                        nan
                                                                      NaN
      2010-05-26 2010-05-26 42.170000
                                             NaN
                                                        nan
                                                                      NaN
```

```
2010-05-27 2010-05-27 44.820000
                                             NaN
                                                         nan
                                                                      NaN
      2010-05-28 2010-05-28 44.420000
                                             NaN
                                                                      NaN
                                                         nan
      2010-05-31 2010-05-31 45.370000
                                             NaN
                                                         nan
                                                                      NaN
      2010-06-01 2010-06-01 44.390000
                                             NaN
                                                                      NaN
                                                         nan
      2010-06-02 2010-06-02 45.320000
                                             NaN
                                                                      NaN
                                                         nan
      2010-06-04 2010-06-04 43.180000
                                             NaN
                                                                      NaN
                                                         nan
      2010-06-07 2010-06-07 41.830000
                                             NaN
                                                                      NaN
                                                         nan
      2010-06-08 2010-06-08 42.270000
                                             NaN
                                                                      NaN
                                                         nan
      2010-06-09 2010-06-09 42.430000
                                             NaN
                                                                      NaN
                                                         nan
      2010-06-10 2010-06-10 43.200000
                                             NaN
                                                                      NaN
                                                         nan
      2010-06-11 2010-06-11 43.730000
                                             NaN
                                                  42.954500
                                                                      NaN
      2010-06-14 2010-06-14 43.750000
                                                  42.893667
                                                                      NaN
                                             NaN
      2010-06-15 2010-06-15 44.380000
                                             NaN
                                                  42.794500
                                                                      NaN
      2010-06-16 2010-06-16 43.830000
                                                  42.720500
                                                                      NaN
                                             NaN
      2010-06-17 2010-06-17 43.050000
                                                  42.662167
                                             NaN
                                                                      NaN
[56]: df['sazonalidade'] = seasonal.values
      df.head(20)
[56]:
                                 preco residuos tendencia sazonalidade
                        data
      date
      2010-05-20 2010-05-20 39.790000
                                             NaN
                                                                  0.999916
                                                         nan
      2010-05-21 2010-05-21 42.460000
                                             NaN
                                                                  1.002028
                                                         nan
      2010-05-24 2010-05-24 42.020000
                                             NaN
                                                         nan
                                                                  1.000593
      2010-05-25 2010-05-25 42.390000
                                             NaN
                                                                  1.000831
                                                         nan
      2010-05-26 2010-05-26 42.170000
                                             NaN
                                                                  1.001943
                                                         nan
      2010-05-27 2010-05-27 44.820000
                                             NaN
                                                         nan
                                                                  1.000149
      2010-05-28 2010-05-28 44.420000
                                             NaN
                                                                  0.998563
                                                         nan
      2010-05-31 2010-05-31 45.370000
                                             NaN
                                                         nan
                                                                  1.000439
      2010-06-01 2010-06-01 44.390000
                                             NaN
                                                                  1.000935
                                                         nan
      2010-06-02 2010-06-02 45.320000
                                             NaN
                                                         nan
                                                                  1.001784
      2010-06-04 2010-06-04 43.180000
                                             {\tt NaN}
                                                                  1.000287
                                                         nan
      2010-06-07 2010-06-07 41.830000
                                             NaN
                                                                  1.001320
                                                         nan
      2010-06-08 2010-06-08 42.270000
                                             NaN
                                                         nan
                                                                  0.999429
      2010-06-09 2010-06-09 42.430000
                                             NaN
                                                                  0.999726
                                                         nan
      2010-06-10 2010-06-10 43.200000
                                             NaN
                                                                  0.997545
                                                         nan
      2010-06-11 2010-06-11 43.730000
                                             NaN
                                                 42.954500
                                                                  0.998549
      2010-06-14 2010-06-14 43.750000
                                             {\tt NaN}
                                                  42.893667
                                                                  0.995032
      2010-06-15 2010-06-15 44.380000
                                             NaN
                                                  42.794500
                                                                  0.995569
      2010-06-16 2010-06-16 43.830000
                                                  42.720500
                                                                  0.991896
                                             NaN
      2010-06-17 2010-06-17 43.050000
                                             NaN
                                                  42.662167
                                                                  0.997500
[57]:
     residuos = residual.values
```

df = df[30:]

[58]:

```
[59]: df['residuos'] = residuos
     df.head()
[59]:
                      data
                              preco
                                     residuos tendencia sazonalidade
     date
     2010-07-02 2010-07-02 39.580000
                                     1.019533 41.746333
                                                             0.999916
     2010-07-05 2010-07-05 39.020000
                                     1.025057 41.743000
                                                              1.002028
     2010-07-06 2010-07-06 39.510000
                                     1.041665 41.738667
                                                              1.000593
     2010-07-07 2010-07-07 40.460000
                                     1.034353 41.739167
                                                              1.000831
     2010-07-08 2010-07-08 40.600000
                                     1.011620 41.757333
                                                              1.001943
     Generate Diferrence
[60]: df['diff_1'] = df['preco'].diff(periods=1)
     df['diff_2'] = df['preco'].diff(periods=2)
     df['diff_3'] = df['preco'].diff(periods=3)
     df['diff_4'] = df['preco'].diff(periods=4)
     df['diff_5'] = df['preco'].diff(periods=5)
     df.dropna(inplace=True)
[61]: df.head(10)
[61]:
                                                                         diff 1 \
                                     residuos tendencia sazonalidade
                      data
     date
     2010-07-12 2010-07-12 40.000000 1.002310 41.827333
                                                              1.000149 -0.600000
     2010-07-13 2010-07-13 40.070000
                                     1.036654 41.910833
                                                             0.998563 0.070000
     2010-07-14 2010-07-14 40.080000
                                     1.028377 41.977833
                                                              1.000439 0.010000
     2010-07-15 2010-07-15 39.760000
                                     1.044658 42.045833
                                                              1.000935 -0.320000
     2010-07-16 2010-07-16 38.880000
                                     1.028132 42.123500
                                                              1.001784 -0.880000
     2010-07-19 2010-07-19 39.970000
                                     1.039199 42.209667
                                                              1.000287 1.090000
     2010-07-20 2010-07-20 42.230000
                                     1.025260 42.292000
                                                              1.001320 2.260000
     2010-07-21 2010-07-21 42.470000
                                     0.977617 42.386167
                                                             0.999429 0.240000
     2010-07-22 2010-07-22 43.370000
                                     0.947756 42.514333
                                                             0.999726 0.900000
     2010-07-23 2010-07-23 43.710000
                                     0.952942
                                               42.666000
                                                             0.997545 0.340000
                   diff 2
                             diff 3
                                      diff 4
                                                diff_5
     date
     2010-07-12 -0.460000 0.490000 0.980000 0.420000
     2010-07-13 -0.530000 -0.390000 0.560000
                                             1.050000
     2010-07-14 0.080000 -0.520000 -0.380000 0.570000
     2010-07-15 -0.310000 -0.240000 -0.840000 -0.700000
     2010-07-16 -1.200000 -1.190000 -1.120000 -1.720000
     2010-07-20 3.350000 2.470000 2.150000 2.160000
     2010-07-21 2.500000 3.590000 2.710000
                                             2.390000
     2010-07-22 1.140000 3.400000 4.490000
                                             3.610000
```

2.1 Save Data

```
[62]: def save_data_cleansing(df: 'dataframe' = None,
                             path: str = 'data/cleansing') -> None:
         df.to_csv(path_or_buf = path,
                    sep = ',',
                    index = False,
                    encoding = 'utf8')
         return "Saved data!"
[63]: df.head()
[63]:
                       data
                                preco residuos tendencia sazonalidade
                                                                            diff_1 \
      date
      2010-07-12 2010-07-12 40.000000 1.002310 41.827333
                                                                1.000149 -0.600000
      2010-07-13 2010-07-13 40.070000 1.036654 41.910833
                                                                0.998563 0.070000
      2010-07-14 2010-07-14 40.080000 1.028377 41.977833
                                                                1.000439 0.010000
      2010-07-15 2010-07-15 39.760000 1.044658 42.045833
                                                                1.000935 -0.320000
      2010-07-16 2010-07-16 38.880000 1.028132 42.123500
                                                                1.001784 -0.880000
                    diff_2
                             diff_3
                                      \mathtt{diff}\_4
                                                 diff_5
      date
      2010-07-12 -0.460000 0.490000 0.980000 0.420000
      2010-07-13 -0.530000 -0.390000 0.560000 1.050000
      2010-07-14 0.080000 -0.520000 -0.380000 0.570000
      2010-07-15 -0.310000 -0.240000 -0.840000 -0.700000
      2010-07-16 -1.200000 -1.190000 -1.120000 -1.720000
[64]: save_data_cleansing(df = df,
                         path = 'data/cleansing/df_vale3_cleansing.csv')
[64]: 'Saved data!'
```