

01-preprocessing_data_exploration

March 21, 2021

1 Pré-processamento e Exploração dos Dados

Aqui vou explorar as características das série temporal - Plotar gráficos de box-plot, histogramas e de linhas por anos - Analisar - distribuição - sazonalidade - tendência - auto-correlação - Teste de estacionariedade

1.1 Importações

```
[1]: # Data analysis and data wrangling
import numpy as np
import pandas as pd

# Metrics
import statistics

# Plotting
from statsmodels.graphics.tsaplots import plot_acf
from statsmodels.graphics.tsaplots import plot_pacf
from pandas.plotting import autocorrelation_plot
from pandas.plotting import lag_plot
import seaborn as sns
import matplotlib.pyplot as plt

from matplotlib import pyplot

# statsmodels
from statsmodels.tsa.stattools import adfuller
from statsmodels.tsa.stattools import acf, pacf
from statsmodels.tsa.seasonal import seasonal_decompose
import statsmodels.tsa.api as smt
import statsmodels.api as sm
import statsmodels.tsa as tsa
import statsmodels.api as sm

# Other
from IPython.display import Image
import warnings
```

```
import pprint
import datetime
import os
```

1.2 Preparação do diretório principal

```
[2]: def prepare_directory_work(end_directory: str='notebooks'):
    # Current path
    curr_dir = os.path.dirname (os.path.realpath ("__file__"))

    if curr_dir.endswith(end_directory):
        os.chdir('..')
        return curr_dir

    return f'Current working directory: {curr_dir}'
```

```
[3]: prepare_directory_work(end_directory='notebooks')
```

```
[3]: '/home/campos/projects/tcc/notebooks'
```

1.3 Formatação das células

```
[4]: # OPTIONAL: Load the "autoreload" extension so that code can change
%load_ext autoreload

# Guarantees visualization inside the jupyter
%matplotlib inline

# Print xxxx rows and columns
pd.set_option('display.max_rows', None)
pd.set_option('display.max_columns', None)
pd.set_option('float_format', '{:f}'.format)

# Suppress unnecessary warnings so that presentation looks clean
warnings.filterwarnings('ignore')

# pretty print
pp = pprint.PrettyPrinter(indent=4)
```

```
[5]: plt.style.use('seaborn') # fivethirtyeight
plt.rc('figure',figsize=(16,8))
plt.rc('font',size=15)
plt.rc('legend',fontsize=15)

# Seaborn rcParams
# =====
```

```
sns.set(context='poster', # notebook
        style='darkgrid',
        palette='deep',
        color_codes=True)

# graph style
sns.set(style='dark', palette='deep')

plt.style.use('fivethirtyeight')
```

1.4 Carregamento dos dados

```
[6]: %%time

df_vale3 = pd.read_csv('data/raw/vale3_2010-2020.csv',
                       encoding='utf8',
                       delimiter=',',
                       verbose=True)
```

Tokenization took: 0.53 ms

Type conversion took: 2.63 ms

Parser memory cleanup took: 0.01 ms

CPU times: user 6.34 ms, sys: 3.22 ms, total: 9.56 ms

Wall time: 11.4 ms

```
[7]: df_vale3.head(15)
```

```
[7]:
```

	Date	Price	Open	High	Low	Vol.	Change %
0	Jun 19, 2020	55.170000	56.330000	56.600000	54.710000	37.86M	-1.78%
1	Jun 18, 2020	56.170000	56.300000	56.540000	55.610000	25.69M	-0.05%
2	Jun 17, 2020	56.200000	55.490000	56.440000	55.150000	27.57M	1.46%
3	Jun 16, 2020	55.390000	55.490000	55.500000	54.220000	29.17M	2.80%
4	Jun 15, 2020	53.880000	52.500000	54.430000	52.130000	27.32M	0.90%
5	Jun 12, 2020	53.400000	53.710000	54.050000	51.980000	31.18M	-1.48%
6	Jun 10, 2020	54.200000	54.910000	55.200000	53.760000	24.19M	-1.44%
7	Jun 09, 2020	54.990000	54.160000	54.990000	54.120000	19.61M	0.38%
8	Jun 08, 2020	54.780000	54.980000	55.650000	53.980000	27.19M	0.31%
9	Jun 05, 2020	54.610000	56.390000	56.700000	54.340000	39.64M	-1.89%
10	Jun 04, 2020	55.660000	53.720000	55.700000	53.520000	37.38M	3.73%
11	Jun 03, 2020	53.660000	53.420000	54.330000	53.390000	-	0.45%
12	Jun 02, 2020	53.420000	53.800000	53.800000	53.000000	25.42M	0.00%
13	Jun 01, 2020	53.420000	52.820000	53.850000	52.500000	27.01M	0.79%
14	May 29, 2020	53.000000	51.400000	53.000000	51.060000	92.24M	5.81%

1.5 Análise Exploratória

1. Colunas: - Date (eixo x): data dos dados - Price (eixo y): é o preço de fechamento. O que será previsto - Open: preço de abertura - High: preço máximo atingido - Low: preço mínimo atingido - Vol.: volume de ações negociadas - Change %: porcentagem de alteração em relação ao dia anterior

2. Contexto: - Mercado de ações - VALE3

Formato dos dados

```
[8]: print("Dataframe:\n{} rows\n{} columns".format(df_vale3.shape[0],
                                                    df_vale3.shape[1]))
```

```
Dataframe:
2495 rows
7 columns
```

Colunas

```
[9]: list_columns = (df_vale3.columns).tolist()

print("-"*25, "List Columns", "-"*25, end='\n')
display(list_columns)
```

```
----- List Columns -----
['Date', 'Price', 'Open', 'High', 'Low', 'Vol.', 'Change %']
```

```
[10]: df_vale3.info()
```

```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 2495 entries, 0 to 2494
Data columns (total 7 columns):
#   Column      Non-Null Count  Dtype
---  -
0   Date        2495 non-null   object
1   Price       2495 non-null   float64
2   Open       2495 non-null   float64
3   High       2495 non-null   float64
4   Low        2495 non-null   float64
5   Vol.       2495 non-null   object
6   Change %   2495 non-null   object
dtypes: float64(4), object(3)
memory usage: 136.6+ KB
```

```
[11]: df_vale3.nunique()
```

```
[11]: Date        2495
      Price       1845
      Open       1816
      High       1852
```

```

Low          1845
Vol.         1339
Change %     927
dtype: int64

```

```

[12]: def show_measures_location(df: 'dataframe', type_descr: 'list') -> None:
        """
        Function get measures localization + total col + % type columns
        Handler when type data not exists

        Args:
        type_descr
            np.number, np.object -> return summary statistic with all columns
            np.number             -> return summary statistic numerical columns
            np.object             -> return summary statistic object columns
        """
        try:
            col = (df.describe(include=type_descr).columns) # pandas.core.indexes.
            ↳base.Index
        except ValueError:
            print(f'Dataframe not contains {type_descr} columns !', end='\n\n')
        else:
            list_col = col.tolist()
            percentage = (len(list_col) / df.shape[1]) * 100

            print("-"*25, "MEASURES OF LOCALIZATION", "-"*25, end='\n\n')
            print(f"TOTAL columns {type_descr}: {len(list_col)}")
            print("PERCENTAGE {} in dataframe: {:.3.4} %".format(type_descr,
            ↳percentage))

            return df.describe(include=type_descr)

```

```

[13]: show_measures_location(df=df_vale3,
                             type_descr=[np.number, np.object])

```

----- MEASURES OF LOCALIZATION -----

```

TOTAL columns [<class 'numpy.number'>, <class 'object'>]: 7
PERCENTAGE [<class 'numpy.number'>, <class 'object'>] in dataframe: 100.0 %

```

```

[13]:
count      Date      Price      Open      High      Low      Vol.  \
unique      2495      nan      nan      nan      nan      1339
top    Apr 25, 2018      nan      nan      nan      nan      3.99M
freq          1      nan      nan      nan      nan      9
mean      NaN    35.801788    35.828188    36.316914    35.315695      NaN
std      NaN    12.277343    12.279942    12.344400    12.184122      NaN

```

min	NaN	8.600000	8.750000	9.060000	8.600000	NaN
25%	NaN	26.880000	26.930000	27.340000	26.605000	NaN
50%	NaN	36.880000	36.870000	37.420000	36.300000	NaN
75%	NaN	46.355000	46.330000	46.830000	45.730000	NaN
max	NaN	62.200000	62.200000	62.420000	60.480000	NaN

	Change %
count	2495
unique	927
top	0.00%
freq	20
mean	NaN
std	NaN
min	NaN
25%	NaN
50%	NaN
75%	NaN
max	NaN

```
[14]: df_vale3.mode(dropna=False, numeric_only=True)
```

```
[14]:
```

	Price	Open	High	Low
0	27.430000	51.000000	38.150000	17.650000
1	nan	nan	44.330000	nan
2	nan	nan	52.090000	nan
3	nan	nan	53.120000	nan

```
[15]: df_vale3.median()
```

```
[15]: Price    36.880000
Open      36.870000
High      37.420000
Low       36.300000
dtype: float64
```

Valores ausentes

```
[16]: df_vale3.isnull().any()
```

```
[16]: Date      False
Price      False
Open      False
High      False
Low      False
Vol.      False
Change %   False
dtype: bool
```

Valores duplicados

```
[17]: df_vale3.duplicated().any()
```

```
[17]: False
```

1.6 Pré-processamento

A análise da ST é univariada, ou seja, somente a coluna **price** em relação ao tempo que será prevista. Isto vai garantir uma melhor comparação entre os modelos estatísticos, de aprendizado de máquina e aprendizado profundo.

```
[18]: def save_image(img: 'matplotlib',
        name: str,
        path: str = 'reports/images/'):

    fig = img.get_figure()
    fig.savefig(f"reports/images/{name}.png")

    return f"Image {name} saved."
```

Remover colunas desnecessárias

```
[19]: df_vale3.drop(['Open', 'High', 'Low', 'Vol.', 'Change %'], axis=1, inplace=True)
```

Todas as colunas em letras minúsculas

```
[20]: df_vale3.columns = map(str.lower, df_vale3.columns)
print(df_vale3.columns)
```

```
Index(['date', 'price'], dtype='object')
```

lista de colunas

```
[21]: list_columns = []
list_columns = df_vale3.columns

list_columns
```

```
[21]: Index(['date', 'price'], dtype='object')
```

1.6.1 Formatação das Colunas

Data

- Transforma o formato da data (Jun 19, 2020) em (2020-06-19)
- Transforma a o tipo da coluna **date** para **datetime64**

```
[22]: df_vale3['date'] = pd.to_datetime(df_vale3['date'])
df_vale3 = df_vale3.iloc[::-1]
```

```
[23]: df_vale3.head(10)
```

```
[23]:
```

	date	price
2494	2010-05-20	39.790000
2493	2010-05-21	42.460000
2492	2010-05-24	42.020000
2491	2010-05-25	42.390000
2490	2010-05-26	42.170000
2489	2010-05-27	44.820000
2488	2010-05-28	44.420000
2487	2010-05-31	45.370000
2486	2010-06-01	44.390000
2485	2010-06-02	45.320000

```
[24]: df_vale3.info()
```

```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 2495 entries, 2494 to 0
Data columns (total 2 columns):
 #   Column  Non-Null Count  Dtype
---  -
 0   date    2495 non-null     datetime64[ns]
 1   price   2495 non-null     float64
dtypes: datetime64[ns](1), float64(1)
memory usage: 39.1 KB
```

1.7 Data como índice

```
[25]: df_vale3_date_index = df_vale3
df_vale3_date_index.index.names = ['date']
df_vale3_date_index.index = df_vale3['date']
df_vale3_date_index.index = pd.to_datetime(df_vale3.index)

print(df_vale3_date_index.index.freq)
print(df_vale3_date_index.index)
```

None

```
DatetimeIndex(['2010-05-20', '2010-05-21', '2010-05-24', '2010-05-25',
               '2010-05-26', '2010-05-27', '2010-05-28', '2010-05-31',
               '2010-06-01', '2010-06-02',
               ...,
               '2020-06-05', '2020-06-08', '2020-06-09', '2020-06-10',
               '2020-06-12', '2020-06-15', '2020-06-16', '2020-06-17',
               '2020-06-18', '2020-06-19'],
              dtype='datetime64[ns]', name='date', length=2495, freq=None)
```



```
[26]: df_vale3_date_index.head()
```

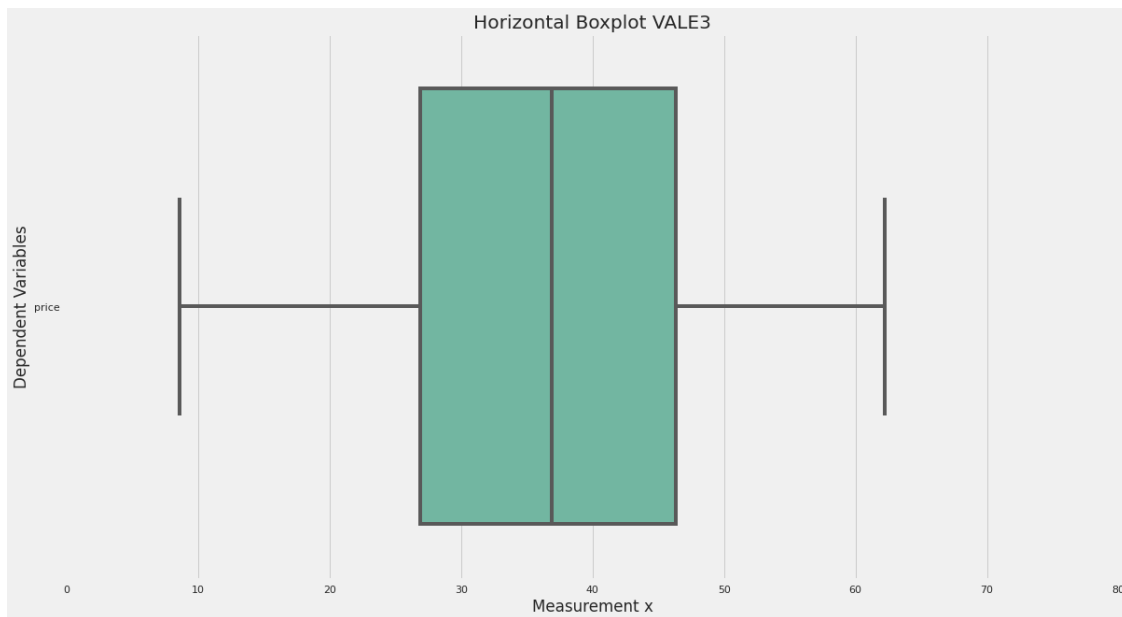
```
[26]:
```

	date	price
date		
2010-05-20	2010-05-20	39.790000
2010-05-21	2010-05-21	42.460000
2010-05-24	2010-05-24	42.020000
2010-05-25	2010-05-25	42.390000
2010-05-26	2010-05-26	42.170000

1.8 Box Plot

```
[27]: def plot_box_plot(df: 'dataframe', data_set_name: str, xlim=None):  
    """  
    Creates a seaborn boxplot including all dependent  
  
    Args:  
    data_set_name: Name of title for the boxplot  
    xlim: Set upper and lower x-limits  
  
    Returns:  
    Box plot with specified data_frame, title, and x-limits  
    """  
    fig, ax = plt.subplots(figsize=(18, 10))  
  
    if xlim is not None:  
        plt.xlim(*xlim)  
  
    plt.title(f"Horizontal Boxplot {data_set_name}")  
  
    plt.ylabel('Dependent Variables')  
    plt.xlabel('Measurement x')  
    ax = sns.boxplot(data = df,  
                    orient = 'h',  
                    palette = 'Set2',  
                    notch = False, # box instead of notch shape  
                    sym = 'rs') # red squares for outliers  
  
    plt.show()
```

```
[28]: plot_box_plot(df_vale3,  
                    'VALE3',  
                    (0, 80))
```



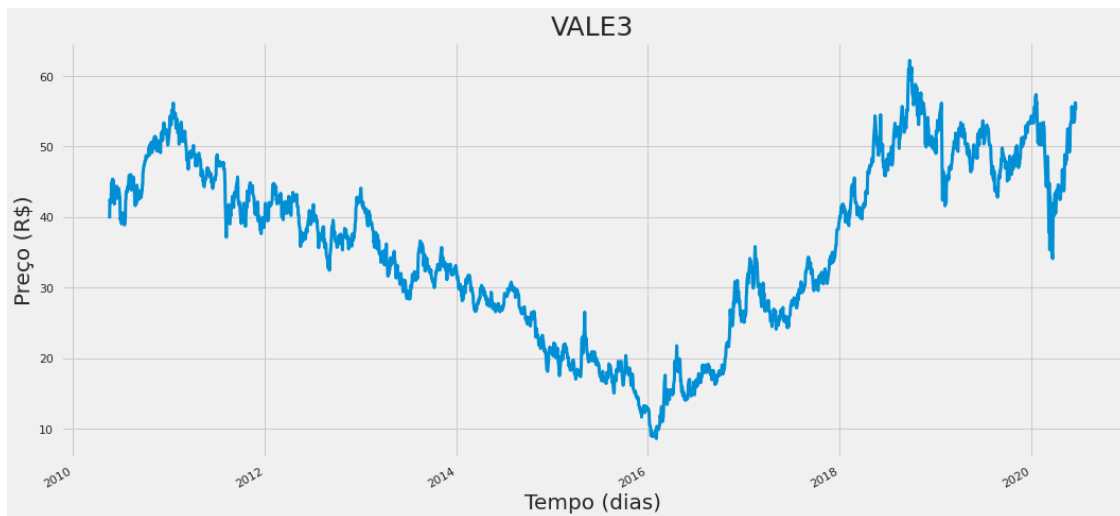
1.9 Análise dos componentes da ST

- distribuição
- sazonalidade
- tendência
- ruídos

Distribuição

```
[29]: img_vale3_distr_line = df_vale3_date_index['price'].plot(linewidth=3)

plt.title(f'VALE3', fontsize=25)
plt.xlabel("Tempo (dias)", fontsize=20)
plt.ylabel("Preço (R$)", fontsize=20)
plt.grid(True)
```




```
[30]: save_image(img=img_vale3_distr_line, name='img_vale3_distr_line')
```

```
[30]: 'Image img_vale3_distr_line saved.'
```

```
[31]: img_vale3_distr_scatter = df_vale3_date_index['price'].plot(style='k.')

plt.title(f'VALE3', fontsize=25)
plt.xlabel("Tempo (dias)", fontsize=20)
plt.ylabel("Preço (R$)", fontsize=20)
plt.grid(True)
```



```
[32]: save_image(img=img_vale3_distr_scatter, name='img_vale3_distr_scatter')
```

```
[32]: 'Image img_vale3_distr_scatter saved.'
```

NOTAS

- Houve uma grande tendência de baixa, começando após alcançar o topo e durou aproximadamente 500 dias.
 - Depois da tendência de baixa avançar o fundo houve reversão de começando um ciclo de alta.
 - No momento aparenta estar em fase de consolidação.
-

1.10 Decomposição da Série Temporal

- O objetivo é decompor a ST
- A ST aparenta ter duas tendências sendo os dois casos uma tendência linear do que exponencial, então a decomposição será **additive**

```
[33]: decomposition_add = seasonal_decompose(df_vale3['price'],
                                             freq=30,
                                             model='multiplicative')


trend = decomposition_add.trend
seasonal = decomposition_add.seasonal
residual = decomposition_add.resid
```

```
[34]: fig, axes = plt.subplots(ncols=1, nrows=3, sharex=True)

axes[0].set_ylabel('Tendência', fontsize=20)
axes[1].set_ylabel('Sazonalidade', fontsize=20)
axes[2].set_ylabel('Resíduo', fontsize=20)
axes[2].set_xlabel('Tempo dias', fontsize=20)


decomposition_add.trend.plot(ax=axes[0])
decomposition_add.seasonal.plot(ax=axes[1])
decomposition_add.resid.plot(ax=axes[2])
```

```
[34]: <AxesSubplot:xlabel='date', ylabel='Resíduo'>
```



```
[35]: df_vale3_without_trend = df_vale3['price'] - trend
img_df_vale3_without_trend = df_vale3_without_trend.plot()
save_image(img=img_df_vale3_without_trend, name='img_df_vale3_without_trend')
```

[35]: 'Image img_df_vale3_without_trend saved.'



```
[36]: df_vale3_without_seasonal = df_vale3['price'] - seasonal
img_df_vale3_without_seasonal = df_vale3_without_seasonal.plot()
save_image(img=img_df_vale3_without_seasonal, ↵
↵name='img_df_vale3_without_seasonal')
```

[36]: 'Image img_df_vale3_without_seasonal saved.'



```
[37]: df_vale3_without_resid = df_vale3['price'] - residual
df_vale3_without_resid = df_vale3_without_resid.plot()
save_image(img=df_vale3_without_resid, name='df_vale3_without_resid')
```

```
[37]: 'Image df_vale3_without_resid saved.'
```



NOTAS:

A decomposição da ST demonstra: - Ocorreram 2 grandes tendências e nos últimos anos o preço não apresenta uma tendência evidente. - A sazonalidade ocorre de 30 em 30 dias. - O que se pode notar é que de 2018 em diante os resíduos aumentaram. Neste mesmo período a ST não apresentou uma tendência clara.

1.11 Auto-correlação

Modelos autoregressivos como ARIMA, supõem que as observações anteriores são úteis para prever o valor da próxima etapa de tempo. Quanto mais forte a correlação entre a variável de saída e uma variável defasada específica, mais peso o modelo de auto-regressão pode colocar nessa variável.

NOTAS:

- A correlação é calculada entre a variável e ela mesma nas etapas de tempo anteriores, por isso o nome autocorrelação.
- Calcular a correlação também podem ajudar escolher as variáveis de atraso serão úteis em um modelo e quais não serão.
- Se as variáveis de atraso mostrarem baixa ou nenhuma correlação com a variável de saída, a série temporal pode não ser previsível.
- Usei Pearson

wiki análise de autocorrelação é uma ferramenta matemática para encontrar padrões repetitivos, como a presença de um sinal periódico obscurecido por ruído ou a identificação da frequência fundamental ausente em um sinal implícito por suas frequências harmônicas . É frequentemente usado no processamento de sinais para analisar funções ou séries de valores, como sinais no domínio do tempo .


```
[38]: df_vale3_date_index['price'].autocorr(lag=1)
```

```
[38]: 0.9972513584845024
```

```
[39]: img_df_vale3_autocorr_1 = lag_plot(df_vale3_date_index['price'], lag=1)
      save_image(img=img_df_vale3_autocorr_1, name='img_df_vale3_autocorr_1')
```

c argument looks like a single numeric RGB or RGBA sequence, which should be avoided as value-mapping will have precedence in case its length matches with **x** & **y**. Please use the **color** keyword-argument or provide a 2-D array with a single row if you intend to specify the same RGB or RGBA value for all points.

```
[39]: 'Image img_df_vale3_autocorr_1 saved.'
```




```
[40]: df_vale3_date_index['price'].autocorr(lag=30)
```

```
[40]: 0.9459357661702158
```

```
[41]: img_df_vale3_autocorr = lag_plot(df_vale3_date_index['price'], lag=30)
save_image(img=img_df_vale3_autocorr, name='img_df_vale3_autocorr')
```

c argument looks like a single numeric RGB or RGBA sequence, which should be avoided as value-mapping will have precedence in case its length matches with **x** & **y**. Please use the **color** keyword-argument or provide a 2-D array with a single row if you intend to specify the same RGB or RGBA value for all points.

```
[41]: 'Image img_df_vale3_autocorr saved.'
```





```
[42]: df_vale3_date_index['price'].autocorr(lag=313)
```

```
[42]: 0.5017662028027128
```

```
[43]: img_df_vale3_autocorr_313 = lag_plot(df_vale3_date_index['price'], lag=313)
save_image(img=img_df_vale3_autocorr_313, name='img_df_vale3_autocorr_313')
```

c argument looks like a single numeric RGB or RGBA sequence, which should be avoided as value-mapping will have precedence in case its length matches with *x* & *y*. Please use the *color* keyword-argument or provide a 2-D array with a single row if you intend to specify the same RGB or RGBA value for all points.

```
[43]: 'Image img_df_vale3_autocorr_313 saved.'
```



```
[44]: df_vale3_date_index['price'].autocorr(lag=314)
```

```
[44]: 0.49925706901064987
```

Até 314 dias ainda possuem correlação.

Visualização da variável lag

```
[45]: df_vale3_original_lag_30 = pd.concat([df_vale3_date_index['price'],
                                          df_vale3_date_index['price'].shift(30)],
                                          axis=1)
```

```
[46]: df_vale3_original_lag_30.head(50)
```

```

[46]:
      date      price      price
2010-05-20 39.790000      nan
2010-05-21 42.460000      nan
2010-05-24 42.020000      nan
2010-05-25 42.390000      nan
2010-05-26 42.170000      nan
2010-05-27 44.820000      nan
2010-05-28 44.420000      nan
2010-05-31 45.370000      nan
2010-06-01 44.390000      nan
2010-06-02 45.320000      nan
2010-06-04 43.180000      nan
2010-06-07 41.830000      nan
2010-06-08 42.270000      nan
2010-06-09 42.430000      nan
2010-06-10 43.200000      nan
2010-06-11 43.730000      nan
2010-06-14 43.750000      nan
2010-06-15 44.380000      nan
2010-06-16 43.830000      nan
2010-06-17 43.050000      nan
2010-06-18 42.650000      nan
2010-06-21 43.980000      nan
2010-06-22 43.550000      nan
2010-06-23 44.090000      nan
2010-06-24 43.100000      nan
2010-06-25 43.630000      nan
2010-06-28 42.810000      nan
2010-06-29 40.740000      nan
2010-06-30 39.610000      nan
2010-07-01 39.780000      nan
2010-07-02 39.580000 39.790000
2010-07-05 39.020000 42.460000
2010-07-06 39.510000 42.020000
2010-07-07 40.460000 42.390000
2010-07-08 40.600000 42.170000
2010-07-12 40.000000 44.820000
2010-07-13 40.070000 44.420000
2010-07-14 40.080000 45.370000
2010-07-15 39.760000 44.390000
2010-07-16 38.880000 45.320000
2010-07-19 39.970000 43.180000
2010-07-20 42.230000 41.830000
2010-07-21 42.470000 42.270000
2010-07-22 43.370000 42.430000
2010-07-23 43.710000 43.200000

```

```

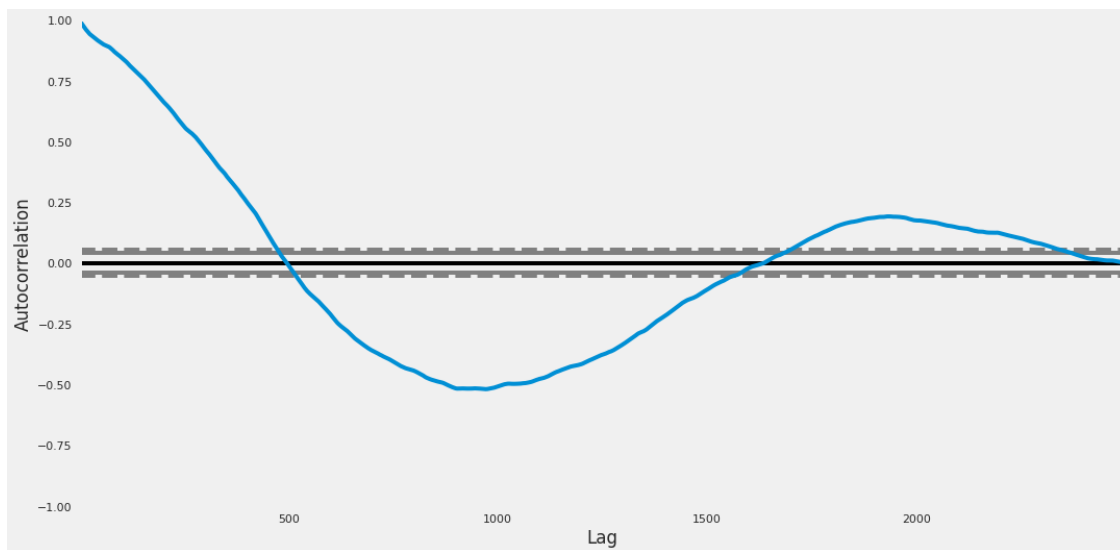
2010-07-26 43.730000 43.730000
2010-07-27 43.550000 43.750000
2010-07-28 44.320000 44.380000
2010-07-29 43.920000 43.830000
2010-07-30 44.050000 43.050000

```

Podemos ver um grande grupo de observações ao longo de uma linha diagonal, mostrando claramente uma relação ou alguma correlação.

```
[47]: img_df_vale3_autocorr_time = autocorrelation_plot(df_vale3_date_index['price'])
      save_image(img=img_df_vale3_autocorr_time, name='img_df_vale3_autocorr_time')
```

```
[47]: 'Image img_df_vale3_autocorr_time saved.'
```



Os intervalos de confiança são de 95% e 99% sugerindo que os valores de correlação fora desse intervalo são muito provavelmente uma correlação e não um acaso estatístico.

1.12 Estacionariedade

É preciso garantir que os dados são estacionários. Significa que a série temporal possui um comportamento ao longo do tempo e que possui uma alta probabilidade de seguir este mesmo comportamento no futuro.

Visualmente a série não é estacionária. Para garantir o comportamento dessa série vou plotar as estatísticas de rolagem(ma, var) e fazer o teste de Dickey-Fuller.

Então neste teste avalio duas hipóteses: - Hipótese nula (H0) : não é estacionária. Tem alguma estrutura dependente do tempo. - Hipótese alternativa (H1) : é estacionária. Não tem estrutura dependente do tempo.

```
[48]: def test_stationarity(timeseries):


    # determing rolling statistics
    rolmean = timeseries.rolling(window=30, center=False).mean()
    rolstd = timeseries.rolling(window=30, center=False).std()

    # plot rolling statistics:
    orig = plt.plot(timeseries, color='blue',label='Original')
    mean = plt.plot(rolmean, color='red', label='Rolling Mean')
    std = plt.plot(rolstd, color='black', label = 'Rolling Std')
    plt.legend(loc='best')
    plt.title('Rolling Mean & Standard Deviation')
    plt.show(block=False)

    # perform Dickey-Fuller test:
    print('Results of Dickey-Fuller Test:')
    dftest = adfuller(timeseries, autolag=None)
    dfoutput = pd.Series(dftest[0:4], index=['Test Statistic','p-value','Lags_
    ↳Used','Number of Observations Used'])
    for key,value in dftest[4].items():
        dfoutput['Critical Value (%s)'%key] = value

    print(dfoutput)
```

```
[49]: test_stationarity(df_vale3['price'])
```



```
Results of Dickey-Fuller Test:
Test Statistic      -0.929286
```

```

p-value                0.778175
Lags Used              27.000000
Number of Observations Used  2467.000000
Critical Value (1%)    -3.433003
Critical Value (5%)    -2.862712
Critical Value (10%)   -2.567394
dtype: float64

```

NOTES

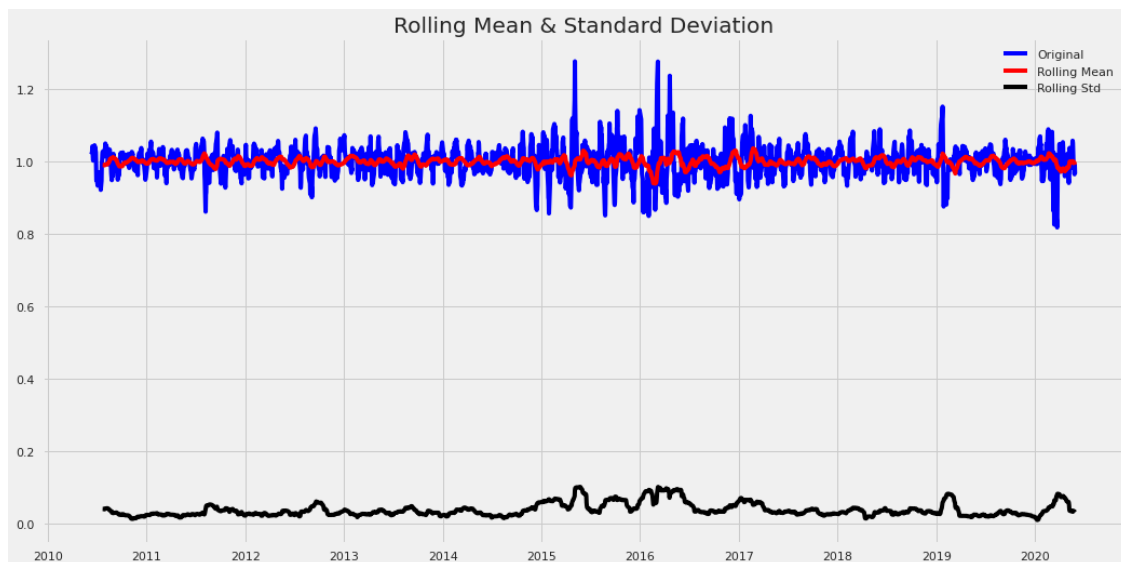
- Usado `autolag='AIC'` para a própria função determinar o lag, escolhendo o menor valor observado.
- **Test Statistic > Critical Value (1%)**, então a H_0 é aceita, ou seja, não se tem estacionariedade na ST explorada
- Neste caso se faz necessário deixar a ST estacionária !

Estacionariedade por Decomposição

```

[50]: residual
      residual.dropna(inplace=True)
      test_stationarity(residual)

```



Results of Dickey-Fuller Test:

```

Test Statistic        -12.432177
p-value               0.000000
Lags Used             27.000000
Number of Observations Used  2437.000000
Critical Value (1%)   -3.433036
Critical Value (5%)   -2.862727
Critical Value (10%)  -2.567402

```

dtype: float64

2 Criação de Novas Características

```
[51]: cols = ['data', 'preco', 'residuos', 'tendencia', 'sazonalidade']
```

```
[52]: df = pd.DataFrame(columns=cols)
df.head()
```

```
[52]: Empty DataFrame
Columns: [data, preco, residuos, tendencia, sazonalidade]
Index: []
```

```
[53]: df['data'] = df_vale3['date']
df.head()
```

```
[53]:
```

	data	preco	residuos	tendencia	sazonalidade
date					
2010-05-20	2010-05-20	NaN	NaN	NaN	NaN
2010-05-21	2010-05-21	NaN	NaN	NaN	NaN
2010-05-24	2010-05-24	NaN	NaN	NaN	NaN
2010-05-25	2010-05-25	NaN	NaN	NaN	NaN
2010-05-26	2010-05-26	NaN	NaN	NaN	NaN

```
[54]: df['preco'] = df_vale3['price']
df.head()
```

```
[54]:
```

	data	preco	residuos	tendencia	sazonalidade
date					
2010-05-20	2010-05-20	39.790000	NaN	NaN	NaN
2010-05-21	2010-05-21	42.460000	NaN	NaN	NaN
2010-05-24	2010-05-24	42.020000	NaN	NaN	NaN
2010-05-25	2010-05-25	42.390000	NaN	NaN	NaN
2010-05-26	2010-05-26	42.170000	NaN	NaN	NaN

```
[55]: df['tendencia'] = trend.values
df.head(20)
```

```
[55]:
```

	data	preco	residuos	tendencia	sazonalidade
date					
2010-05-20	2010-05-20	39.790000	NaN	nan	NaN
2010-05-21	2010-05-21	42.460000	NaN	nan	NaN
2010-05-24	2010-05-24	42.020000	NaN	nan	NaN
2010-05-25	2010-05-25	42.390000	NaN	nan	NaN
2010-05-26	2010-05-26	42.170000	NaN	nan	NaN

2010-05-27	2010-05-27	44.820000	NaN	nan	NaN
2010-05-28	2010-05-28	44.420000	NaN	nan	NaN
2010-05-31	2010-05-31	45.370000	NaN	nan	NaN
2010-06-01	2010-06-01	44.390000	NaN	nan	NaN
2010-06-02	2010-06-02	45.320000	NaN	nan	NaN
2010-06-04	2010-06-04	43.180000	NaN	nan	NaN
2010-06-07	2010-06-07	41.830000	NaN	nan	NaN
2010-06-08	2010-06-08	42.270000	NaN	nan	NaN
2010-06-09	2010-06-09	42.430000	NaN	nan	NaN
2010-06-10	2010-06-10	43.200000	NaN	nan	NaN
2010-06-11	2010-06-11	43.730000	NaN	42.954500	NaN
2010-06-14	2010-06-14	43.750000	NaN	42.893667	NaN
2010-06-15	2010-06-15	44.380000	NaN	42.794500	NaN
2010-06-16	2010-06-16	43.830000	NaN	42.720500	NaN
2010-06-17	2010-06-17	43.050000	NaN	42.662167	NaN

```
[56]: df['sazonalidad'] = seasonal.values
df.head(20)
```

```
[56]:
```

	data	preco	residuos	tendencia	sazonalidad
date					
2010-05-20	2010-05-20	39.790000	NaN	nan	0.999916
2010-05-21	2010-05-21	42.460000	NaN	nan	1.002028
2010-05-24	2010-05-24	42.020000	NaN	nan	1.000593
2010-05-25	2010-05-25	42.390000	NaN	nan	1.000831
2010-05-26	2010-05-26	42.170000	NaN	nan	1.001943
2010-05-27	2010-05-27	44.820000	NaN	nan	1.000149
2010-05-28	2010-05-28	44.420000	NaN	nan	0.998563
2010-05-31	2010-05-31	45.370000	NaN	nan	1.000439
2010-06-01	2010-06-01	44.390000	NaN	nan	1.000935
2010-06-02	2010-06-02	45.320000	NaN	nan	1.001784
2010-06-04	2010-06-04	43.180000	NaN	nan	1.000287
2010-06-07	2010-06-07	41.830000	NaN	nan	1.001320
2010-06-08	2010-06-08	42.270000	NaN	nan	0.999429
2010-06-09	2010-06-09	42.430000	NaN	nan	0.999726
2010-06-10	2010-06-10	43.200000	NaN	nan	0.997545
2010-06-11	2010-06-11	43.730000	NaN	42.954500	0.998549
2010-06-14	2010-06-14	43.750000	NaN	42.893667	0.995032
2010-06-15	2010-06-15	44.380000	NaN	42.794500	0.995569
2010-06-16	2010-06-16	43.830000	NaN	42.720500	0.991896
2010-06-17	2010-06-17	43.050000	NaN	42.662167	0.997500

```
[57]: residuos = residual.values
```

```
[58]: df = df[30:]
```

```
[59]: df['residuos'] = residuos
df.head()
```

```
[59]:
```

	data	preco	residuos	tendencia	sazonalidade
date					
2010-07-02	2010-07-02	39.580000	1.019533	41.746333	0.999916
2010-07-05	2010-07-05	39.020000	1.025057	41.743000	1.002028
2010-07-06	2010-07-06	39.510000	1.041665	41.738667	1.000593
2010-07-07	2010-07-07	40.460000	1.034353	41.739167	1.000831
2010-07-08	2010-07-08	40.600000	1.011620	41.757333	1.001943

Generate Diference

```
[60]: df['diff_1'] = df['preco'].diff(periods=1)
df['diff_2'] = df['preco'].diff(periods=2)
df['diff_3'] = df['preco'].diff(periods=3)
df['diff_4'] = df['preco'].diff(periods=4)
df['diff_5'] = df['preco'].diff(periods=5)

df.dropna(inplace=True)
```

```
[61]: df.head(10)
```

```
[61]:
```

	data	preco	residuos	tendencia	sazonalidade	diff_1	\
date							
2010-07-12	2010-07-12	40.000000	1.002310	41.827333	1.000149	-0.600000	
2010-07-13	2010-07-13	40.070000	1.036654	41.910833	0.998563	0.070000	
2010-07-14	2010-07-14	40.080000	1.028377	41.977833	1.000439	0.010000	
2010-07-15	2010-07-15	39.760000	1.044658	42.045833	1.000935	-0.320000	
2010-07-16	2010-07-16	38.880000	1.028132	42.123500	1.001784	-0.880000	
2010-07-19	2010-07-19	39.970000	1.039199	42.209667	1.000287	1.090000	
2010-07-20	2010-07-20	42.230000	1.025260	42.292000	1.001320	2.260000	
2010-07-21	2010-07-21	42.470000	0.977617	42.386167	0.999429	0.240000	
2010-07-22	2010-07-22	43.370000	0.947756	42.514333	0.999726	0.900000	
2010-07-23	2010-07-23	43.710000	0.952942	42.666000	0.997545	0.340000	

	diff_2	diff_3	diff_4	diff_5
date				
2010-07-12	-0.460000	0.490000	0.980000	0.420000
2010-07-13	-0.530000	-0.390000	0.560000	1.050000
2010-07-14	0.080000	-0.520000	-0.380000	0.570000
2010-07-15	-0.310000	-0.240000	-0.840000	-0.700000
2010-07-16	-1.200000	-1.190000	-1.120000	-1.720000
2010-07-19	0.210000	-0.110000	-0.100000	-0.030000
2010-07-20	3.350000	2.470000	2.150000	2.160000
2010-07-21	2.500000	3.590000	2.710000	2.390000
2010-07-22	1.140000	3.400000	4.490000	3.610000

2010-07-23 1.240000 1.480000 3.740000 4.830000

2.1 Save Data

```
[62]: def save_data_cleansing(df: 'dataframe' = None,
                                path: str = 'data/cleansing') -> None:
    df.to_csv(path_or_buf = path,
              sep = ',',
              index = False,
              encoding = 'utf8')

    return "Saved data!"
```

```
[63]: df.head()
```

```
[63]:
```

	data	preco	residuos	tendencia	sazonalidade	diff_1	\
date							
2010-07-12	2010-07-12	40.000000	1.002310	41.827333	1.000149	-0.600000	
2010-07-13	2010-07-13	40.070000	1.036654	41.910833	0.998563	0.070000	
2010-07-14	2010-07-14	40.080000	1.028377	41.977833	1.000439	0.010000	
2010-07-15	2010-07-15	39.760000	1.044658	42.045833	1.000935	-0.320000	
2010-07-16	2010-07-16	38.880000	1.028132	42.123500	1.001784	-0.880000	

	diff_2	diff_3	diff_4	diff_5
date				
2010-07-12	-0.460000	0.490000	0.980000	0.420000
2010-07-13	-0.530000	-0.390000	0.560000	1.050000
2010-07-14	0.080000	-0.520000	-0.380000	0.570000
2010-07-15	-0.310000	-0.240000	-0.840000	-0.700000
2010-07-16	-1.200000	-1.190000	-1.120000	-1.720000

```
[64]: save_data_cleansing(df = df,
                            path = 'data/cleansing/df_vale3_cleansing.csv')
```

```
[64]: 'Saved data!'
```
